

2024 건강검진정보 EDA 보고서

코드잇 데이터 분석 부트캠프 스프린트 미션 4
작성자: 이지현

1. 분석 개요

본 보고서는 2024년 건강검진정보 데이터를 활용하여 주요 건강지표의 분포와 집단별 차이를 탐색적으로 살펴보는 것을 목적으로 하였다. 전체 변수 중에서는 건강위험과 직접적으로 연결해 해석할 수 있는 BMI, 혈압, 식전혈당, 흡연상태, 성별, 연령대를 중심으로 분석을 진행하였다. 이를 통해 비만도 분포, 고혈압 위험, 혈당 이상 경향이 어떤 집단에서 두드러지는지 확인하고, 건강검진 데이터에서 나타나는 주요 패턴을 도출하고자 하였다.

2. 데이터 구조 및 변수 확인

해당 데이터는 건강검진 대상자의 기본 정보와 건강 상태 관련 지표를 포함하고 있으며, 인구학적 특성을 나타내는 변수와 신체, 건강 수치를 나타내는 변수가 함께 구성되어 있다.

2-1. 전체 컬럼 설명

컬럼명	의미	비고	데이터 성격
기준년도	해당 정보의 기준 연도	연도 정보 (예: 2024)	범주형
가입자일련번호	검진자에게 부여된 고유 번호	1 ~ 1000000	식별자
시도코드	검진자의 거주 지역 시도 코드	시도 코드 체계 참고	범주형
성별코드	검진자의 성별 코드	1=남자, 2=여자	범주형
연령대코드	나이를 5세 단위로 구분한 연령대 코드	연령대 코드 체계 참고	범주형
신장	검진자의 키	5cm 단위로 내림 (예: 100~104cm → 100cm)	수치형
체중	검진자의 몸무게	5kg 단위로 내림 (예: 25~29kg → 25kg)	수치형
허리둘레	검진자의 허리둘레	cm 단위	수치형
시력_좌	좌안 시력	0.1~2.5 사이로 표기, 0.1 이하의 시력은 0.1, 실명은 9.9로 표기	수치형
시력_우	우안 시력	0.1~2.5 사이로 표기, 0.1 이하의 시력은 0.1, 실명은 9.9로 표기	수치형
청력_좌	좌측 청력 상태	1=정상, 2=비정상	범주형
청력_우	우측 청력 상태	1=정상, 2=비정상	범주형
수축기혈압	최고 혈압	mmHg 단위	수치형
이완기혈압	최저 혈압	mmHg 단위	수치형
식전혈당	공복 혈당 수치	mg/dL 단위	수치형
흡연상태	흡연 여부 및 상태	1=비흡연, 2=금연, 3=흡연	범주형
음주여부	음주 여부	0=비음주, 1=음주	범주형

2-2. 시도 코드 체계

코드	시도명	코드	시도명
11	서울특별시	42	강원도
26	부산광역시	43	충청북도
27	대구광역시	44	충청남도
28	인천광역시	45	전라북도
29	광주광역시	46	전라남도
30	대전광역시	47	경상북도
31	울산광역시	48	경상남도
36	세종특별자치시	49	제주특별자치도
41	경기도		

2-3. 연령대 코드 체계

코드	연령대	코드	연령대
1	0~4세	10	45~49세
2	5~9세	11	50~54세
3	10~14세	12	55~59세
4	15~19세	13	60~64세
5	20~24세	14	65~69세
6	25~29세	15	70~74세
7	30~34세	16	75~79세
8	35~39세	17	80~84세
9	40~44세	18	85세+

2-4. 데이터 구조 및 타입 확인

데이터는 총 100만 건의 규모로 확인되었으며 컬럼 수는 17개이다. 자료형 확인 결과 대부분의 값이 숫자 형태로 저장되어 있었으나 건강 관련 지표를 나타내는 수치형 변수와 개인의 특성을 구분하는 범주형 변수도 함께 포함되어 있어 모두를 수치형 변수로 볼 수 없다. 따라서 실제로는 코드값이므로 이후 분석 과정에서 해석의 편의를 위해 문자열 형태로 치환하여 범주형 변수로 구분해 다루었다.

3. 데이터 전처리

3-1. 결측값 처리

결측값 처리는 모든 변수에 동일한 기준을 적용하지 않고 변수의 성격에 따라 범주형 변수와 수치형 변수를 나누어 서로 다른 방식으로 처리하였다.

먼저 결측값 현황을 확인한 결과, 허리둘레, 시력_좌, 시력_우, 청력_좌, 청력_우, 수축기혈압, 이완기혈압, 식전혈당, 흡연상태, 음주여부 컬럼에서 결측값이 확인되었다.

▼ 결측값이 확인된 변수의 결측 개수와 비율

결측 존재 변수	결측 개수	결측 비율	결측 존재 변수	결측 개수	결측 비율
허리둘레	495개	0.0495%	수축기혈압	5790개	0.5790%
시력_좌	193개	0.0495%	이완기혈압	5789개	0.5789%
시력_우	192개	0.0192%	식전혈당	5847개	0.5847%
청력_좌	148개	0.0148%	흡연상태	118개	0.0118%
청력_우	148개	0.0148%	음주여부	45개	0.0045%

3-1-1. 범주형 변수 결측값 처리

청력_좌, 청력_우, 흡연상태, 음주여부는 ‘특정 상태를 구분’ 하는 범주형 변수에 해당한다. 이러한 변수는 평균이나 중앙값을 계산하더라도 해석상 의미가 없으므로 가장 자주 나타나는 범주값인 최빈값으로 결측값을 대체하는 것이 가장 자연스럽다고 보았다.

범주형 변수에서의 최빈값 대체는 전체 분포를 크게 훼손하지 않으면서 결측값을 처리할 수 있다. 특히 이번 경우처럼 결측 비율이 매우 크지 않은 경우에는, 최빈값으로 대체하는 방식이 전체 범주 분포를 크게 왜곡하지 않으면서 분석을 이어갈 수 있는 가장 기본적이고 안정적인 방법이라고 판단하였다. 따라서 청력_좌, 청력_우, 흡연상태, 음주여부의 결측값은 각 변수의 최빈값으로 대체하여 처리하였다.

3-1-2. 수치형 변수 결측값 처리

• 허리둘레, 혈압, 혈당 변수 결측값 처리

허리둘레, 수축기혈압, 이완기혈압, 식전혈당은 모두 건강 상태를 나타내는 대표적인 수치형 변수이다. 이러한 변수들은 개인의 신체 조건이나 건강 상태에 따라 값의 차이가 크게 나타날 수 있으며, 특히 ‘성별과 연령’에 따라 분포가 달라질 가능성이 높다. 허리둘레는 성별에 따라 기본적인 체형 차이가 존재할 수 있고 혈압이나 혈당 역시 연령 증가에 따라 분포 양상이 달라질 수 있다. 따라서 이 변수들의 결측값을 전체 데이터의 평균 또는 중앙값 하나로 대체하는건 각 집단의 특성을 충분히 반영하지 못할 수 있다고 보았다.

이러한 점을 고려하여 허리둘레, 수축기혈압, 이완기혈압, 식전혈당은 같은 성별코드와 같은 연령대코드를 가진 집단 내의 중앙값으로 결측값을 대체하였다. 즉, 결측이 발생한 행의 값을 무작정 전체 대표값으로 채우는 대신 해당 행과 동일한 성별과 동일한 연령대에 속한 사람들의 값 분포를 기준으로 대표값을 구해 반영한 것이다.

이 방법을 선택한 근거로는 크게 두 가지이다. 첫째, 같은 성별과 같은 연령대 집단은 전체 데이터보다 상대적으로 유사한 특성을 가질 가능성이 높기 때문에, 이 집단의 중앙값을 사용하는 것이 해당 개인의 값을 추정하는 데 더 적절하다고 판단하였다. 둘째, 허리둘레, 혈압, 혈당은 건강 상태에 따라 높은 값이나 낮은 값이 존재할 수 있는데 여기서의 평균은 이 극단값의 영향을 받을 가능성이 있으므로 평균보다는 중앙값이 더 안정적인 대표값이라고 판단하였다.

• 시력 변수 결측값 처리

시력_좌, 시력_우는 수치형 변수로 볼 수 있으나, 일반적인 연속형 변수와는 조금 다르게 해석할 필요가 있었다. 데이터 설명에 따르면 시력은 0.1에서 2.5 사이의 값으로 기록되며 실명은 9.9로 표기된다. 즉, 9.9는 단순히 큰 수가 아니라 일반적인 시력 수치와는 다른 의미를 갖는 특수한 ‘코드값’이라는 것이다.

이 때문에 시력 변수의 결측값을 대체할 때, 9.9를 일반적인 시력값과 같은 방식으로 포함하여 대표값을 계산하는 것은 적절하지 않다고 판단하였다. 실명은 일반적이지 않은 특수한 경우이기 때문이다. 따라서 시력_좌와 시력_우의 결측값은 실명값인 9.9를 제외한 나머지 값들만을 사용해 중앙값을 계산한 뒤 대체하였다. 여기서도 평균이 아니라 중앙값을 사용한 이유는 시력 데이터 역시 일부 극단값의 영향을 받을 수 있기 때문이다.

3-1-3. 결측값 처리 요약

결측값 처리에서는 모든 변수를 하나의 기준으로 처리하지 않고, 각 변수의 자료형과 의미를 기준으로 구분해 처리하였다. 이러한 방식은 결측값 처리 이후에도 데이터가 원래 가지고 있던 특성을 최대한 유지하기 위한 것이다. 결측값을 무조건 삭제하거나 전체 평균으로 일괄 대체할 경우, 특정 변수의 분포가 왜곡되거나 실제 집단별 차이가 희석될 수 있기 때문이다.

결측값 처리 이후 다시 각 컬럼의 결측 여부를 확인한 결과, 분석에 사용한 주요 변수들의 결측값은 모두 처리된 것을 확인할 수 있었다.

▼ 결측값 처리 요약

결측 존재 변수	유형	처리 방식	처리 근거
청력_좌, 청력_우, 흡연상태, 음주여부	범주형	최빈값 대체	상태를 구분하는 코드값이므로 평균/중앙값보다 최빈값이 적절
허리둘레, 수축기혈압, 이완기혈압, 식전혈당	수치형	성별+연령대별 중앙값 대체	성별, 연령에 따라 분포 차이가 있을 수 있기 때문에 집단 특성을 반영하고 극단값 영향 최소화
시력_좌, 시력_우	수치형	특수값(9.9) 제외 후 중앙값 대체	실명값 9.9는 일반 시력값과 의미가 달라 대표값 계산에서 제외

3-2. 이상치 처리

이상치 처리는 필요한 값을 바로 확인하기 위해 Plotly Express 라이브러리의 상자그림(Box Plot)을 통해 우선적으로 확인하였으며, 통계적으로 멀리 떨어져 있는 값이 보인다고 해서 모두 제거하지는 않았다. 건강검진 데이터의 경우 일반적인 수치 데이터와 달리 크거나 작은 값이 실제 건강 상태를 반영할 가능성이 있기 때문이다. 따라서 처리 시, 상자그림상 이상치로 표시된 값과 실제로 오류 가능성이 높은 값을 구분하도록 하였다. 즉, 분포상 드문 값이라는 이유만으로 일괄 제거하지 않고 변수의 의미와 건강지표로서의 특성을 함께 고려해 이상치 여부를 판단하였다. 그 기준에 대한 근거를 찾기 위해서는 질병관리청 국가건강정보포털을 참고하였다.

3-2-1. 신장

IQR 기반 이상치 범위	135 미만 (=130)	190 초과 (=195)
IQR 기반 이상치 개수	241건	92건
처리 방법	제거	유지

신장 변수는 상자그림상 특정 값(130, 195cm)의 이상치가 확인되었다. 신장은 개인 간 차이가 큰 신체 지표이며, 분포상 평균에서 멀리 떨어진 값이라 하더라도 실제로 존재 가능한 범위의 값일 수 있다. 국민건강보험공단 건강검진통계 저신장 자료에서는 2017년 대한소아청소년과학회 성장도표를 기준으로 최종 성인 신장이 남자 평균 173.4cm, 여자 평균 160.7cm라고 설명하고 있다. 이는 성인 신장이 일정한 평균값 주변에 분포하되, 그보다 크거나 작은 값 역시 실제로 존재할 수는 있음을 보여준다.

우선 두 이상치 중 195cm 라는 신장을 가진 총 92건의 데이터는 값을 직접 확인한 결과, 특정 비현실적인 연령대에만 몰려 있지 않고 여러 성인 연령대에서 관측되었으며, 관측된 92건은 모두 성별이 남자인 검진자에게서 나타난 값이었다. 195cm는 평균보다 큰 값이기는 하지만 성인, 특히 남자 신체 측정값으로 전혀 불가능한 수준이라고 보기 어렵다. 따라서 신장 195cm는 분포상 드문 값일 수는 있어도, 현실적으로 가능한 연령대에 분포해있으며 성별이 모두 남자라는 점을 고려하였을 때 일반적인 건강검진 데이터에서 관측이 가능한 값으로 판단하여 제거하지 않고 유지하였다.

반면, 130cm 의 값은 다르게 판단하였다. 이는 총 241건이었으며 이 데이터를 모두 확인한 결과, 130cm의 값도 성인 연령대 전반에 걸쳐 분포하고 있었다. 그러나 질병관리청 자료가 성인의 평균 신장을 남자 173.4cm, 여자 160.7cm 수준으로 제시하고 있다는 점을 고려하면, 130cm는 단순히 평균보다 작은 값이 아니라 성인 검진 데이터의 일반적인 분포와 비교했을 때 지나치게 낮은 수준으로 판단할 수 있다. 특히 해당 값이 특정 특수 집단이 아

나라 다양한 성인 연령대에서 반복적으로 나타났다는 점에서, 이를 실제 신장 분포라기보다 입력 또는 기록 오류 가능성이 높은 값으로 보았다. 따라서 이 값은 일반적인 성인 건강검진 데이터에서 반복적으로 관측된다 보기에 는 매우 이례적이라 판단하여 총 241건을 모두 제거하였다.

3-2-2. 체중

IQR 기반 이상치 범위	30 미만	105 초과
IQR 기반 이상치 개수	-	7399건
IQR 기반 이상치 최소, 최대값	-	135
처리 방법	-	유지

체중 역시 상자그림상 105kg 초과 값(max: 135kg)이 이상치로 표시되었다. 체중은 신장과 마찬가지로 개인차가 큰 신체 지표이며, 평균보다 상당히 큰 값이 존재하더라도 실제 비만 상태나 고도비만 상태를 반영할 수 있다. 질병관리청 국가건강정보포털의 ‘비만 어떻게 관리해야 할까요?’ 자료에서는 비만 정도를 평가할 때 단순히 체중만 보지 않고, 체질량지수(BMI)를 활용해 키와 체중을 함께 고려한다고 설명하고 있다.

즉 체중은 그 자체만으로 비정상 여부를 판단하기보다는, 신장과 함께 해석해야 하는 변수이다. 체중 변수에서의 (110~135kg)와 같은 값은 분포상 드물 수는 있어도, 성인의 비만 또는 고도비만 상태에서 실제로 나타날 수 있는 범위로 볼 수 있다. 즉, 분포상 큰 수치의 값이라는 이유만으로 모두 제거할 경우, 실제 비만 집단의 특성을 과도하게 손실할 가능성이 있다. 따라서 체중 변수의 이상치로 나온 값에 대해서는 유지하는 방향을 선택하였다.

3-2-3. 허리둘레

IQR 기반 이상치 범위	52.3 미만	110.2 초과
IQR 기반 이상치 개수	177건	8296건
IQR 기반 이상치 최소, 최대값	6.8	999

허리둘레는 상자그림상 이상치가 비교적 많이 나타난 변수였으나, 높은 값 자체를 곧바로 오류라고 볼 수는 없었다. 질병관리청 국가건강정보포털의 한 보도자료에 따르면, 허리둘레는 복부비만 판단에 활용되는 대표적인 건강지표이고 복부비만 기준은 남성은 90cm 이상, 여성은 85cm 이상으로 제시된다. 이는 허리둘레가 실제 건강 상태를 반영하는 변수라는 점을 보여주며, 큰 값이 존재한다는 사실만으로 비정상값이라고 판단할 수 없음을 의미한다.

이에 따라 허리둘레는 상자그림상 이상치로 표시된 값 전체를 제거하지 않고 실제 측정값으로 보기 어려운, 이상치 중에서도 분포도가 낮은 극단값만 제거하였다. 허리둘레의 이상치 값을 직접 확인한 결과, 50 전후부터 110대 이상까지 일정한 범위 안에서 연속적으로 분포하였고 극단적으로 6.8, 10, 43, 44, 45.3... 170, 210, 999 같은 값도 포함되어 있었다. 이런 값들은 다른 이상치들과 비교했을 때 지나치게 동떨어져 있고 성인 건강검진의 허리둘레로 보기 어려워 오류 가능성이 높다고 판단하였다. 반면 50 이상, 150 이하 구간의 값들은 드물 수는 있어도 연속적인 관측값으로는 나타났기 때문에 50 미만과 150 초과 값을 이상치로 간주하고 총 19건을 제거하였다.

이 기준은 의학적 기준 자체를 그대로 적용한 것은 아니며, 허리둘레가 건강지표라는 점을 고려했을 때 높은 값 전체를 제거하는 대신 명백한 입력 오류 가능성이 높은 극단값만 최소한으로 제거하기 위한 보수적 기준으로 설정하였다.

3-2-4. 혈압

혈압 변수는 수축기혈압과 이완기혈압으로 나누어 각 변수에 대해 다시 고혈압의 값과 저혈압의 값을 구분하여 해석하였다. 혈압은 건강 상태에 따라 실제로 높거나 낮은 값이 나타날 수 있는 대표적인 건강지표이기 때문에 건강검진 측정값으로 보기 어려운 극단값만 보수적으로 제거하는 방식으로 처리하였다.

• 수축기혈압

IQR 기반 이상치 범위	82 미만	162 초과
IQR 기반 이상치 개수	291건	9235건
IQR 기반 이상치 최소, 최대값	60	271

질병관리청 국가건강정보포털에 따르면, 고혈압은 일반적으로 수축기혈압 140mmHg 이상 또는 이완기혈압 90mmHg 이상으로 설명된다. 또한 국가건강정보포털의 운동 자료 중 고혈압 환자의 운동 항목에서는 수축기 혈압이 200mmHg를 초과하거나 이완기 혈압이 115mmHg를 초과하는 경우 운동을 금한다고 안내하고 있으며 혈압이 180/110mmHg 이상인 경우에는 약물치료를 시작한 후 근력 강화 운동을 추가하도록 제시하고 있다.

따라서 상한선을 초과하는 이상치, 특히 180mmHg 이상 또는 200mmHg를 넘는 값은 정상 범위는 아니지만 질병관리청 자료에서 실제 관리가 필요한 혈압 수준으로 제시되고 있다. 따라서 통계적으로 드문 값일 수는 있어도 건강검진 데이터에서 전혀 관측될 수 없는 값이라고 단정하기 어렵다고 보아, 수축기혈압에서 IQR 기반 상한선을 초과하는 이상치는 제거하지 않고 유지하였다.

질병관리청의 저혈압 자료에서는 일반적으로 수축기혈압 90mmHg 미만 또는 이완기혈압 60mmHg 미만을 저혈압으로 설명하고 있다. 다만 같은 자료에서, 저혈압이 단순히 수치만으로 판단되는 것이 아니라 혈압이 낮아지는 속도와 이에 대한 적응 정도, 동반 증상 등을 함께 고려해야 한다고 설명한다. 특히 혈압이 천천히 떨어질 경우에는 수축기혈압이 80mmHg 정도까지 낮아져도 별다른 증상이 없거나 단순 피로감만 느끼는 경우가 있을 수 있다고 제시하고 있다.

이러한 내용을 고려하면, 하한선 미만인 이상치도 곧바로 입력 오류라고 단정하기 어렵다. 본 데이터에서 수축기혈압의 이상치 최저값은 60mmHg였는데, 이는 매우 낮은 수치이기는 하지만 질병관리청 자료상 저혈압은 수치만으로 판단되지 않으며, 낮은 혈압 역시 실제 건강 상태를 반영할 가능성이 있다. 따라서 수축기혈압에서 IQR 기반 하한선 미만인 이상치 역시 일괄 제거하지 않고 유지하였다.

• 이완기혈압

IQR 기반 이상치 범위	49 미만	100 초과
IQR 기반 이상치 개수	1453건	11943건
IQR 기반 이상치 최소, 최대값	11	182

이완기혈압 역시 위에서 언급한 질병관리청 국가건강정보포털 기준에서 90mmHg 이상이면 고혈압 범주에 해당할 수 있다. 또한 운동 자료에서는 이완기혈압이 115mmHg를 초과하는 경우 운동을 금한다고 제시하고 있어서 높은 이완기혈압 수치 또한 실제 건강관리 상황에서 다루어지는 값을 확인할 수 있다.

이에 따라 이완기혈압에서도 상한선을 초과한 이상치는 제거하지 않고 유지하였다. 즉, 높은 이완기혈압도 분포상 드물 수는 있어도 실제 고혈압 상태를 반영할 가능성이 있다 판단하여 통계적 이상치라는 이유만으로 제거하지 않았다.

저혈압 자료에서는 일반적으로 이완기혈압 60mmHg 미만을 저혈압 범주로 설명하였다. 또한 급성 저혈압은 쇼크와 같은 응급상황으로 이어질 수 있으며, 매우 낮은 혈압은 증상과 함께 해석해야 한다고 제시하고 있다.

본 데이터에서 이완기혈압의 하한선 미만의 이상치들을 확인한 결과, 그중 30mmHg 미만의 값들은 다른 이상치와 달리 연속적으로 나타나지 않으며, 일반적인 저혈압 기준과 비교하더라도 건강검진 환경에서 정상적인 측정값으로 보기 어려운 수준이라고 판단하였다. 물론 이론적으로 매우 낮은 혈압이 응급상황에서 나타날 수는 있으나, 이번 데이터는 일반적인 건강검진 정보라는 점을 고려할 때 이완기혈압 30mmHg 미만은 실제 건강 상태를 반영한 값이라기보다 입력 오류 또는 측정 오류 가능성이 높은 값으로 해석하는 것이 더 타당하다고 보았다. 따라서 이완기혈압은 전체 유지가 아닌 30mmHg 미만의 값을 이상치로 간주하여 총 3건을 제거하였다.

3-2-5. 식전혈당

식전혈당은 건강 상태를 직접적으로 반영하는 대표적인 혈액검사 지표이며, 특히 혈당은 정상 범위를 벗어난 높은 값과 낮은 값이 모두 실제 질환 상태와 연결될 수 있기 때문에 통계적 분포뿐 아니라 건강지표로서의 의미를 함께 고려하여 진행하였다.

IQR 기반 이상치 범위	64 미만	131 초과
IQR 기반 이상치 개수	1903건	60596건
IQR 기반 이상치 최소, 최대값	17	991

질병관리청 국가건강정보포털 당뇨병 자료에 따르면, 정상 공복 혈장 포도당은 100mg/dL 미만, 공복혈당장애는 100~125mg/dL, 당뇨병 진단 기준은 8시간 이상 공복 후 혈장 포도당 126mg/dL 이상으로 제시된다. 즉 식전혈당이 126mg/dL을 넘는 값은 실제 당뇨병 또는 고혈당 상태를 반영할 수 있는 수치로 해석할 수 있다. 따라서 131mg/dL 초과와 같이 높은 식전혈당 값은 상자그림상 이상치로 표시되더라도 제거를 하는 것은 옳지 않다. 또한 질병관리청 국가건강정보포털 고혈당 자료에서는 고혈당을, 넓은 의미로는 정상 혈당보다 높은 경우, 좁은 의미로는 혈당이 250mg/dL 이상인 경우로 설명하고 있으며, 250mg/dL 이상으로 지속되면 고혈당에 의한 급성 합병증이 생길 수 있다고 제시하고 있다. 여기서 이 급성 합병증의 경우에는 자가혈당측정기로 측정한 혈당이 300mg/dL 이상인 경우가 많고, 심한 경우는 혈당이 600mg/dL 이상으로도 측정이 됨을 보여준다.

즉, 600mg/dL 이상의 값도 실제 임상적 상황에서 관측이 가능한 값을 확인할 수 있었다. 따라서 300mg/dL, 400mg/dL, 500mg/dL, 600mg/dL대의 식전혈당 값은 실제 고혈당 상태를 반영할 가능성이 있다고 보고 제거하지 않았다. 다만 700mg/dL 이상의 값은 분포가 낮은, 동떨어진 일부 소수의 극단값으로 확인되었다. 질병관리청 자료에서는 250mg/dL 이상, 300~400mg/dL 이상의 현저한 고혈당에 대해서는 설명하고 있으나, 700mg/dL 이상과 같은 매우 극단적인 수치에 대해 일반 건강검진 데이터에서의 해석 기준이나 상한선을 직접 제시하고 있지는 않았다. 이에 따라 질병관리청 자료로 근거를 확인할 수 있는 높은 혈당 범위까지는 유지하되, 700mg/dL 이상은 상자그림의 이상치 내에서도 극단적으로 드물게 나타난 값이라는 점을 고려하여 이상치로 간주하고 총 6건을 제거하였다.

식전혈당의 낮은 값 역시 단순히 작은 수치라는 이유만으로 곧바로 제거하지 않았다. 질병관리청 국가건강정보포털 당뇨병 합병증 자료에서 저혈당은 혈당 수치가 70 mg/dL 미만으로 제시하고 있으며 당뇨병 환자의 약물요법 자료에서는 45~50mg/dL 이하에서도 나타나며 이 경우 혈당치만으로 진단하지 않고 저혈당 증세와 당분 투여 후 증상 소실 여부 등을 종합적으로 판단한다고 설명하고 있다. 또한 저혈당은 심한 경우 생명을 잃을 수도 있다고 제시하고 있어, 매우 낮은 혈당이 실제로는 단순한 통계적 이상치가 아니라 의학적으로도 매우 위험한 상태일 수 있음을 알 수 있다.

이러한 기준을 바탕으로 본 분석에서는 식전혈당의 낮은 값 중 40mg/dL 미만은 일반적인 건강검진 환경에서 그대로 유지하기보다는, 극단적으로 낮은 값으로 보아 보수적으로 제거하는 것이 적절하다고 판단하였다. 실제 데이터에서도 17, 20, 23, 25, 28, 29, 30, 32, 33, 36, 39와 같이 40mg/dL보다 낮은 값들이 확인되었는데, 이러한 값들은 질병관리청이 제시한 저혈당 범위와 비교했을 때 일반적인 식전혈당 분포에서나 저혈당 의심 수치에서나 낮은 수준에 해당한다. 따라서 본 분석에서는 40mg/dL 미만의 식전혈당 값은 이상치로 간주하여 총 15건을 제거하였다.

3-2-6. 이상치 처리 요약

정리하면, 본 분석에서는 이상치를 변수의 의미와 실제 건강 상태에서의 관측 가능성을 함께 고려하여 처리하였다. 이에 따라 신장·체중·혈압처럼 실제로 나타날 수 있는 값은 최대한 유지하고, 허리둘레·이완기혈압·식전혈당에서는 해석상 비현실적인 극단값만 최소한으로 제거하였다.

▼ 이상치 처리 요약

이상치 존재 변수	처리 방식	처리 근거	제거한 이상치 수
신장	190cm 초과(195cm) 유지, 135cm 미만(130cm) 제거	195cm는 실제 관측 가능한 값으로 판단, 130cm는 성인 건강검진 데이터에서 비현실적인 값으로 판단하여 제거	241
체중	전부 유지	고체중은 비만 또는 고도비만 상태에서 실제 관측 가능하므로 제거하지 않음	-
허리둘레	50cm 미만, 150cm 초과 제거	허리둘레는 복부비만 판단 지표이므로 전체를 제거하지 않고, 최극단값만 제거	19
수축기혈압	전부 유지	높은 값과 낮은 값 모두 실제 건강 상태에서 관측 가능하다고 보아 유지	-
이완기혈압	30mmHg 미만 제거	일반적인 건강검진 측정값으로 보기 어려운 극단값으로 판단하여 제거	3
식전혈당	40mg/dL 미만, 700mg/dL 이상 제거	매우 낮은 값은 저혈당 기준과 비교해 극단값으로 보고 제거, 매우 높은 값 중 700 이상은 소수의 극단값으로 판단하여 제거	21

3-2-7 시력 변수 이상치 확인

시력 변수(시력좌, 시력우)에 대해서도 값의 분포와 이상 여부를 함께 점검하였다. 데이터 설명상 시력은 0.1 이상 2.5 이하의 범위로 기록되며 0.1 이하의 시력은 0.1로, 실명은 9.9로 표기되는 특성이 있다. 따라서 단순히 일반적인 연속형 변수의 이상치 기준을 그대로 적용하기보다는 변수 정의 자체를 고려하여 해석할 필요가 있다고 판단하였다. 확인 결과, 시력 변수에서 관측된 값들은 모두 데이터 설명에서 제시된 범위와 특수 코드 체계 내의 값으로 판단되어, 별도의 제거 또는 추가 대체 처리는 수행하지 않았다.

3-3. 범주형 변수 코드값 점검 및 처리

범주형 변수에 대해서는 이상치 여부를 수치형 변수와 같은 방식으로 판단하기 어렵기 때문에, 각 변수에 대해 데이터 설명에 제시된 코드값 외에 다른 값이 존재하는지 확인하였다. 점검 대상은 기준년도, 시도코드, 성별코드, 연령대코드, 청력_좌, 청력_우, 흡연상태, 음주여부였으며, 각 컬럼의 실제 고유값을 데이터 설명에 제시된 범주와 비교하는 방식으로 확인하였다.

확인 결과 기준년도, 시도코드, 성별코드, 연령대코드, 흡연상태, 음주여부는 모두 데이터 설명에 제시된 범위 내의 코드값으로만 구성되어 있었다. 반면 청력_좌와 청력_우에서는 설명상 존재해야 하는 값인 1(정상), 2(비정상) 외에 3이라는 값이 추가로 확인되었다. 따라서 3은 청력 변수에서 정의되지 않은 비정상 코드값으로 판단하였다.

이 값은 청력_좌와 청력_우에서 각각 약 2,300건 정도 확인되었으며, 이를 모두 제거할 경우 불필요한 데이터 손실이 발생할 수 있다고 보았다. 또한 청력 변수는 범주형 변수이므로, 앞서 결측값 처리에서 사용한 방식과 동일하게 최빈값으로 대체하는 것이 가장 일관된 처리 방식이라고 판단하였다. 이에 따라 청력_좌, 청력_우에서 3으로 기록된 값은 각 변수의 최빈값으로 대체하였다.

3-4. 중복값 확인

중복값 확인은 각 검진 대상을 구분하는 식별자인 가입자일련번호를 기준으로 진행하였으며, 동일한 가입자일련번호가 반복해서 나타나는 행이 있는지 점검하였다. 확인 결과 가입자일련번호 기준 중복 데이터는 존재하지 않았으며, 따라서 중복 제거 과정은 별도로 수행하지 않았다.

3-5. 범주형 코드값의 문자열 변환

본 데이터에는 일부 범주형 변수가 숫자 형태의 코드값으로 저장되어 있었다. 예를 들어 시도코드, 연령대코드, 성별코드, 흡연상태, 음주여부는 모두 숫자로 기록되어 있었지만, 실제로는 연속적인 수치를 의미하는 것이 아니라 특정 범주를 구분하기 위한 값에 해당한다. 따라서 이러한 변수들은 숫자 그대로 두는 것보다, 각 코드가 의미하는 문자열로 변환하는 것이 해석과 시각화에 더 적절하다고 판단하였다.

이에 따라 코드값을 실제 의미를 가지는 문자열로 변환하였다. 예를 들어 성별코드는 1을 남성, 2를 여성으로 변환하였고, 흡연상태는 비흡연, 금연, 흡연과 같이 해석 가능한 범주명으로 변경하였다. 시도코드와 연령대코드 역시 각각 실제 시도명과 연령대 문자열로 변환하였다.

▼ 범주형 코드값 변환 요약

변수	변환 전	변환 후
시도코드	숫자 코드	시도명
연령대코드	숫자 코드	연령대 문자열
성별코드	1, 2	남성, 여성
흡연상태	1, 2, 3	비흡연, 금연, 흡연
음주여부	0, 1	비음주, 음주

3-6. 파생변수 생성

본 분석에서는 기존 변수만으로 건강 상태를 해석하는 데 한계가 있다고 판단하여, 신장과 체중을 활용한 BMI(체질량지수) 파생변수를 추가로 생성하였다. BMI는 체중(kg)을 신장(m)의 제곱으로 나누어 계산하는 대표적인 체격 지표로, 비만도와 건강 위험을 함께 살펴볼 때 자주 활용된다. 신장과 체중은 이미 결측값이 없고, 이상치 처리 이후에도 분석 가능한 상태로 정리되어 있었기 때문에 이를 바탕으로 BMI를 산출하였다.

4. 기술통계량 확인

전처리를 완료한 이후, 주요 변수들의 전반적인 분포와 값의 범위를 확인하기 위해 기술통계량을 살펴보았다. 이를 통해 전처리 이후 데이터가 어떤 분포를 보이는지 점검하고, 이후 시각화 및 그룹별 비교 분석의 기초 자료로 활용하고자 하였다. 전처리 이후 최종 분석에 사용된 데이터 수는 **999,716건**이다.

4-1. 수치형 변수

▼ 수치형 변수 기술통계량

변수	count	mean	std
신장	999,716	162.74	9.34
체중	999,716	64.57	14.02
허리둘레	999,716	81.56	10.78
시력_좌	999,716	0.95	0.57
시력_우	999,716	0.95	0.57
수축기혈압	999,716	122.73	14.56
이완기혈압	999,716	75.22	10.33
식전혈당	999,716	100.98	22.85

변수	min	25%	50%	75%	max
신장	135.0	155.0	165.0	170.0	195.0
체중	30.0	55.0	65.0	75.0	135.0
허리둘레	50.0	74.0	81.2	88.5	150.0
시력_좌	0.1	0.7	0.9	1.2	9.9
시력_우	0.1	0.7	0.9	1.2	9.9
수축기혈압	60.0	112.0	121.0	132.0	271.0
이완기혈압	25.0	68.0	75.0	81.0	182.0
식전혈당	45.0	89.0	97.0	106.0	693.0

신장과 체중은 평균과 중앙값의 차이가 크지 않아 비교적 안정적인 분포를 보였다. 허리둘레는 개인차가 다소 크게 나타났으며, 혈압과 식전혈당은 평균값은 안정적이지만 높은 값이 일부 포함되어 있어 건강위험 구간을 함께 살펴볼 필요가 있었다.

4-2. 범주형 변수

범주형 변수는 기준년도, 가입자일련번호, 거주지, 성별, 연령대, 청력_좌, 청력_우, 흡연, 음주를 대상으로 확인하였다.

▼ 범주형 변수 기술통계량

변수	count	unique	top	freq
기준년도	999,716	1	2024	999,716
가입자일련번호	999,716	999,716	-	-
거주지	999,716	17	경기도	268,679
성별	999,716	2	남성	517,900
연령대	999,716	14	50-54	123,986
청력_좌	999,716	2	1.0	967,370
청력_우	999,716	2	1.0	968,572
흡연	999,716	3	비흡연	643,651
음주	999,716	2	음주	656,915

우선 가입자일련번호는 중복 없는 식별자였다. 거주지는 경기도 비중이 가장 높았고, 성별은 남성이 더 많았다. 연령대는 50-54세가 가장 많았으며, 청력은 정상 범주가 대부분이었다. 생활습관 변수에서는 비흡연 비중이 가장 높았고, 음주는 음주 응답 비중이 더 높게 나타났다.


5. 주요 변수 분포 탐색

전처리를 완료한 건강검진 데이터를 바탕으로 주요 변수들의 전반적인 분포를 탐색하였다.

5-1. 주요 신체 계측 변수의 분포

신체 계측 변수인 신장, 체중, 허리둘레의 분포를 확인하였다.

▼ 신장, 체중, 허리둘레 분포 히스토그램




신장은 전체적으로 약 150~175cm 구간에 관측치가 집중되어 있었으며, 160cm 전후를 중심으로 비교적 대칭적인 분포를 보였다. 극단적으로 낮거나 높은 값은 일부 존재하였으나, 전체적으로는 중심 구간에 자료가 밀집된 안정적인 형태를 나타냈다.

체중은 약 45~80kg 구간에 관측치가 많이 분포하였고, 중심 구간 이후 고체중 방향으로 꼬리가 길게 이어지는 분포를 보였다. 이는 체중 변수가 신장보다 상대적으로 편차가 크고, 일부 고체중 집단이 함께 포함되어 있음을 보여준다.

허리둘레 역시 중심 구간에 관측치가 밀집되어 있었으나, 체중과 유사하게 오른쪽으로 꼬리가 길게 늘어나는 분포를 나타냈다. 특히 70~90cm 구간에 많은 관측치가 몰려 있었으며, 이후 높은 값 구간으로 갈수록 빈도는 감소하지만 일정 수준의 관측치가 계속 존재하였다.

▼ 신장, 체중, 허리둘레 분포 박스플롯




신장, 체중, 허리둘레를 박스플롯으로 함께 비교한 결과, 신장은 비교적 안정적인 사분위 범위를 보인 반면 체중과 허리둘레는 상단 방향의 극단값이 상대적으로 더 많이 관찰되었다. 특히 허리둘레는 높은 값 영역에서 이상치가 다수 존재하였는데, 이는 단순 오류라기보다 실제 건강 이상 상태를 반영할 가능성이 있으므로 이후 분석에서도 그대로 해석할 필요가 있다.

5-2. 혈압 및 혈당 변수의 분포

건강 상태와 직접적으로 관련성이 높은 수축기혈압, 이완기혈압, 식전혈당의 분포를 확인하였다.

▼ 수축기혈압, 이완기혈압, 식전혈당 분포 히스토그램




수축기혈압은 약 110~135mmHg 구간에 관측치가 가장 많이 분포하였으며, 중심 구간 이후 오른쪽으로 꼬리가 길게 이어지는 형태를 보였다. 이는 대부분의 검진자가 일반적인 혈압 범위에 포함되지만, 일부 고혈압 구간의 관측치가 함께 존재함을 의미한다.

이완기혈압은 약 65~85mmHg 구간에 자료가 집중되어 있었고, 수축기혈압과 마찬가지로 우측 치우침 분포를 나타냈다. 다만 수축기혈압보다 전체 분포 범위는 다소 좁게 형성되었으며, 상대적으로 안정적인 중심 구간이 확인되었다.

식전혈당은 대부분의 관측치가 약 80~110mg/dL 구간에 몰려 있었으나, 혈압 변수보다 더 뚜렷한 우측 치우침을 보였다. 즉 중심 구간은 비교적 좁지만, 높은 혈당값이 뒤쪽 꼬리를 길게 형성하는 구조를 나타냈다. 다만 여기서는 전체 분포의 형태를 보다 명확히 확인하기 위해 200mg/dL 이하 구간만을 중심으로 시각화하였으며, 이를 통해 정상 범위 부근에 관측치가 집중되어 있으면서도 일부 고혈당 집단이 함께 존재함을 확인할 수 있었다.


▼ 수축기혈압, 이완기혈압, 식전혈당 분포 박스플롯



세 변수를 박스플롯으로 함께 비교한 결과, 수축기혈압과 이완기혈압은 비교적 좁은 사분위 범위를 중심으로 분포하였으나 상단 방향의 이상치가 일부 존재하였다. 반면 식전혈당은 상단 방향의 극단값이 더 넓게 퍼져 있었으며, 건강검진 데이터 특성상 실제 대사 이상 상태를 반영하는 값들이 포함되어 있음을 보여주었다.

5-3. 성별과 연령대 분포

▼ 성별 비율 파이차트와 연령대 분포 히스토그램




성별과 연령대 분포를 확인한 결과, 성별은 남성과 여성이 모두 큰 비중으로 포함되어 있었으며, 남성이 약간 더 높은 비율을 차지하였다. 그러나 한쪽 성별에 극단적으로 치우친 자료는 아니므로, 이후 성별에 따른 건강지표 비교를 수행하기에 적절한 자료 구조를 갖추고 있다고 볼 수 있다.

연령대 분포는 20대부터 85세 이상까지 비교적 넓은 구간에 걸쳐 자료가 분포하고 있었으며, 특히 40대 후반부터 60대 초반 구간에서 상대적으로 높은 빈도를 보였다. 반면 20대 초반과 80대 이상 구간은 상대적으로 낮은 빈도를 나타냈다.

5-4. 생활습관 관련 변수의 분포

생활습관 변수로는 흡연 상태와 음주 여부의 분포를 확인하였다.

▼ 흡연 상태와 음주 여부 분포 히스토그램



흡연 상태 분포를 보면 비흡연 집단의 비중이 가장 높았으며, 금연과 흡연 집단은 상대적으로 비슷한 규모를 보였다. 이후 흡연 상태별 혈압·혈당 비교 시 기준 집단으로 해석하기에 적절함을 시사한다.

음주 여부 분포를 살펴본 결과, 음주 집단이 비음주 집단보다 더 높은 비중을 차지하였다. 즉, 전체 데이터에서는 비음주보다 음주 응답자가 더 많았으며, 따라서 이후 음주 여부에 따른 건강지표 비교에서도 집단 간 차이를 함께 확인할 필요가 있다고 판단하였다.

6. 주요 분석 시각화


이번 주요 분석에서는 건강검진 데이터에 포함된 다양한 변수 가운데, 질병 위험과 직접적으로 연결해 해석할 수 있는 변수들을 중심으로 살펴보았다. 건강검진 데이터에는 시력, 청력, 지역, 성별, 연령대, 흡연, 음주, 신장, 체중, 허리둘레, 혈압, 식전혈당 등 여러 변수가 포함되어 있었지만, 건강 이상 상태를 설명하는 데 핵심적인 지표를 중심으로 분석 축을 세우는 것이 더 의미 있다고 판단하였다.

특히 이번 데이터는 단순 인구통계 정보가 아니라 실제 건강검진 결과를 담고 있기 때문에, 최종 결론 역시 ‘어떤 집단에서 건강 위험 신호가 더 크게 나타나는가’라는 방향으로 도출하는 것이 적절하다고 보았다. 이에 따라 BMI, 혈압, 식전혈당, 흡연상태, 성별, 연령대를 중심 변수로 선정하였다.

6-1. 비만도 분포와 인구집단별 차이

6-1-1. 성별·연령대별 평균 BMI

▼ 성별·연령대별 평균 BMI 라인 그래프




성별·연령대별 평균 BMI를 살펴본 결과, 남성은 젊은 성인기부터 중년 초반까지 BMI가 비교적 높게 나타났고, 이후 연령이 증가할수록 점차 감소하는 흐름을 보였다. 특히 남성은 30대 후반 구간에서 평균 BMI가 가장 높게 나타났으며, 이후 40대, 50대, 60대로 갈수록 완만하게 낮아지는 패턴을 보였다.

반면 여성은 20대 초반에는 남성보다 평균 BMI가 낮게 시작하지만, 연령이 높아질수록 점진적으로 증가하는 모습을 보였다. 여성의 평균 BMI는 20대부터 70대 초반까지 꾸준히 상승하는 흐름을 보였고, 70대 이후에는 남성과 비슷하거나 일부 구간에서는 더 높은 수준으로 나타났다.

이 결과는 성별에 따라 BMI 변화 양상이 다르게 나타날 수 있음을 보여준다. 즉, 남성은 상대적으로 이른 연령대에서 체격 지표가 높게 나타난 뒤 감소하는 경향이 있는 반면, 여성은 연령 증가와 함께 BMI가 점차 높아지는 패턴이 확인되었다.

6-1-2. 연령대별 비만도 비중

▼ 연령대별 비만도 비중 누적 막대 그래프



연령대별 비만도 비중을 보면, 20대 초반은 정상체중 비중이 상대적으로 높고 비만 비중은 낮은 편이었다. 그러나 30대 이후로 갈수록 정상체중 비중은 감소하고, 과체중 및 비만 비중이 커지는 경향이 나타났다.

특히 35~49세 구간에서는 비만 비중이 눈에 띄게 높아져, 중년 전후 구간에서 체중 관리 위험이 상대적으로 커질 가능성을 시사하였다.

이후 50대 후반~70대 구간에서는 정상체중 비중이 다시 일부 회복되는 모습이 보였지만, 과체중 비중은 여전히 일정 수준 이상 유지되었다.

또한 80대 이후에는 저체중 비율이 다시 증가하는 양상도 확인되었다.


이러한 결과를 종합하면, 비만 경향은 청년층보다는 중년층에서 상대적으로 두드러지며, 매우 고령층에서는 다시 저체중 비중이 늘어나는 식으로 연령대에 따라 다른 체격 분포가 형성된다고 볼 수 있다.

6-2. 고혈압 위험의 주요 패턴

위의 질병관리청 자료에 따라 고혈압 여부는 수축기혈압이 140mmHg 이상이거나 이완기혈압이 90mmHg 이상인 경우로 정의하였다.

6-2-1. 성별·연령대별 고혈압 비율

▼ 성별·연령대별 고혈압 비율 라인 그래프




성별·연령대별 고혈압 비율을 보면, 남성과 여성 모두 연령이 증가할수록 고혈압 비율이 뚜렷하게 상승하였다. 이는 혈압이 연령 증가의 영향을 크게 받는 건강지표라는 점을 다시 보여주는 결과이다.

다만 성별에 따라 증가 양상에는 차이가 있었다. 남성은 20대부터 여성보다 높은 고혈압 비율을 보이며 비교적 이른 시기부터 증가세가 나타났고, 40~60대 구간에서도 여성보다 높은 수준을 유지하였다. 반면 여성은 젊은 연령대에서는 고혈압 비율이 낮지만, 60대 이후 급격히 상승하여 70대 이후에는 남성을 넘어서는 구간이 나타났다.

이는 고혈압 위험이 단순히 “남성이 더 높다” 또는 “고령층이 더 높다”는 한 문장으로만 설명되지 않음을 보여준다. 실제로는 젊은~중년층에서는 남성의 위험이 더 크게 나타나고, 고령층에서는 여성의 증가폭이 더 가파르게 나타나는 구조로 해석할 수 있다.

6-2-2. BMI 구간별 평균 혈압

▼ BMI 구간별 평균 혈압 라인 그래프




BMI 구간별 평균 혈압을 보면, BMI가 높아질수록 수축기혈압과 이완기혈압이 모두 함께 상승하는 매우 뚜렷한 경향이 나타났다. 저체중에서 정상, 과체중, 1단계 비만, 고도 비만으로 갈수록 두 혈압 지표가 모두 꾸준히 증가하였고, 특히 수축기혈압은 BMI 상승에 따라 더 뚜렷하게 높아졌다.

이 결과는 BMI가 단순 체격 지표에 그치지 않고, 혈압과도 밀접하게 연결될 수 있음을 시사한다. 즉, 비만도가 높아질수록 혈압 부담 역시 커지는 방향성이 분명하게 관찰되었으며, 이는 비만 관리가 단순 체중 문제를 넘어서 심혈관계 건강과도 연결될 수 있음을 보여준다.

6-3. 혈당 이상 및 당뇨 위험 패턴

위의 질병관리청 자료에 따라 식전혈당 100mg/dL 미만은 정상, 100~125mg/dL는 공복혈당장애, 126mg/dL 이상은 당뇨병 의심 구간으로 나누었다.

▼ 비만도별 혈당 상태 비율 누적 막대 그래프



비만도별 혈당 상태 비율을 비교한 결과, BMI가 높아질수록 정상 혈당 비율은 감소하고, 공복혈당장애 및 당뇨 의심 비율은 증가하는 뚜렷한 패턴이 확인되었다.


저체중 집단에서는 정상 혈당 비중이 가장 높았고, 당뇨의심 비율은 가장 낮았다. 정상체중 집단에서도 비교적 안정적인 분포가 유지되었지만, 과체중 집단부터는 공복혈당장애 비율이 높아지기 시작했고, 비만 집단에서는 정상 비율이 크게 낮아지는 대신 공복혈당장애와 당뇨의심 비중이 함께 커졌다.

즉, 비만도가 증가할수록 혈당 상태 역시 불리한 방향으로 이동하는 경향이 나타났다고 볼 수 있다. 이는 BMI가 혈압뿐 아니라 혈당 이상과도 연결될 수 있는 중요한 설명 변수임을 뒷받침한다.

6-4. 생활습관과 건강지표의 연관성

6-4-1. 흡연 상태별 고혈압 및 당뇨의심 비율

▼ 흡연 상태별 고혈압 및 당뇨의심 비율 막대 그래프




흡연 상태별 고혈압 및 당뇨의심 비율을 비교하면, 비흡연 집단이 가장 낮은 비율을 보였고, 금연 및 흡연 집단에서는 상대적으로 높은 수준이 나타났다. 특히 고혈압 비율은 금연 집단에서 가장 높고, 흡연 집단이 그다음을 보였으며, 비흡연 집단이 가장 낮았다. 당뇨의심 비율 역시 비흡연보다 금연과 흡연 집단에서 더 높게 나타났다.

이 결과는 흡연 상태에 따라 건강위험 수준이 차이를 보일 수 있음을 보여준다. 다만 여기서 금연 집단의 비율이 가장 높게 나타난 점은 단순히 “금연이 더 위험하다”라고 해석해서는 안 된다. 실제로는 건강 이상을 경험한 뒤 금연한 사람, 즉 기저 건강위험이 이미 높은 집단이 금연 범주에 포함되었을 가능성도 존재한다. 따라서 이 그래프는 흡연 상태와 건강위험 사이에 관련성이 있음을 보여주는 자료로는 의미가 있지만, 인과관계를 단정하는 근거로 사용하기에는 한계가 있다.

그럼에도 전체적으로 보면 비흡연 집단이 가장 안정적인 수준을 보였고, 흡연 또는 금연 경험이 있는 집단에서 고혈압·혈당 이상 비율이 더 높게 나타났다는 점에서 생활습관 변수 역시 건강위험 해석에 중요한 보조 변수임을 확인할 수 있다.

6-4-2. 음주 여부별 고혈압 및 당뇨의심 비율

▼ 음주 여부별 고혈압 및 당뇨의심 비율 막대 그래프



음주 여부에 따른 고혈압 및 당뇨의심 비율을 비교한 결과, 비음주 집단에서 음주 집단보다 고혈압 비율과 당뇨 의심 비율이 모두 더 높게 나타났다. 즉, 이번 데이터에서는 음주 응답자보다 비음주 응답자 집단에서 두 건강위험 지표의 비율이 더 크게 관찰되었다.

다만 이러한 결과를 단순히 ‘음주를 하지 않을수록 더 위험하다’는 식으로 해석하기에는 한계가 있다. 건강검진 데이터에서 비음주 집단에는 원래 건강상 이유로 음주를 피하고 있는 사람이나, 이미 질환 위험이 있어 생활습관을 조절하고 있는 사람이 포함되어 있을 가능성도 있기 때문이다. 따라서 이 결과는 음주 여부와 건강위험 간의 단순 분포 차이를 보여주는 자료로는 의미가 있지만, 직접적인 인과관계로 해석하기보다는 집단 특성이 반영된 차이일 수 있음을 함께 고려할 필요가 있다.

즉, 음주 여부 변수는 흡연 변수와 마찬가지로 건강지표와의 관련성을 보조적으로 확인하는 데에는 활용할 수 있으나, 단독으로 건강위험의 방향성을 설명하는 변수로 보기에는 제한적이라고 판단하였다.

7. 결론

이번 주요 분석은 건강검진 데이터에 포함된 여러 변수 중에서 질병 위험과 직접적으로 연결되는 BMI, 혈압, 식전혈당, 흡연상태, 음주여부, 성별, 연령대를 중심으로 진행하였다. 분석 결과, 건강위험은 하나의 변수만으로 설명되기보다 연령, 성별, 비만도, 생활습관이 함께 얹혀 나타나는 구조를 보인다는 점을 확인할 수 있었다.

우선 비만 경향은 연령과 성별에 따라 서로 다른 흐름을 보였다. 남성은 30~40대 전후에서 평균 BMI가 높게 나타난 뒤 점차 감소하는 경향을 보인 반면, 여성은 연령이 증가할수록 BMI가 점진적으로 높아지는 양상이 나타났다. 또한 연령대별 비만도 비율을 통해 중년층에서는 비만 비중이 높아지고, 고령층에서는 저체중 비중이 다시 증가하는 특징도 함께 확인되었다. 이러한 결과는 체격 관련 건강위험 역시 연령대와 성별에 따라 다르게 나타날 수 있음을 보여준다.

또한 BMI는 혈압과 혈당 모두와 연결되는 핵심 변수로 확인되었다. BMI가 높아질수록 평균 수축기혈압과 이완기혈압이 함께 상승하였고, 혈당 상태 역시 정상 비율은 줄어드는 대신 공복혈당장애와 당뇨병의 비율이 높아지는 경향을 보였다. 즉, 비만은 단순한 체격의 문제가 아니라 혈압과 혈당 이상 위험과도 맞물린 건강지표로 해석할 수 있었다.

고혈압 위험은 연령 증가와 함께 전반적으로 상승하는 경향을 보였다. 특히 남성은 젊은 연령대부터 여성보다 높은 고혈압 비율을 보였고, 여성은 고령층에서 증가폭이 더 크게 나타나 일부 구간에서는 남성을 넘어서는 모습도 확인되었다. 이는 혈압 관련 위험이 단순히 한 집단에서만 높게 나타나는 것이 아니라, 성별과 연령에 따라 서로 다른 방식으로 증가할 수 있음을 시사한다.

생활습관 변수 역시 건강지표와 일정한 관련성을 보였다. 흡연 상태별 비교에서는 비흡연 집단이 상대적으로 낮은 고혈압 및 당뇨병의 비율을 보였고, 금연 및 흡연 집단에서는 더 높은 비율이 나타났다. 음주 여부별 비교에서는 비음주 집단에서 고혈압 및 당뇨병의 비율이 더 높게 나타났으나, 이는 단순히 음주 여부만의 영향이라기보다 건강상 이유로 음주를 제한하고 있는 집단의 특성이나 기존 건강 상태가 함께 반영된 결과일 가능성이 있다. 따라서 흡연과 음주 변수는 직접적인 인과관계를 설명하는 변수라기보다는 건강위험과의 관련성을 보조적으로 보여주는 변수로 해석하는 것이 적절하다.

종합하면, 이번 건강검진 데이터에서는 중년층의 비만 경향, 고령층의 고혈압 증가, BMI 상승에 따른 혈압·혈당 악화, 생활습관 집단 간 건강지표 차이가 주요한 패턴으로 확인되었다. 따라서 건강검진 데이터의 주요 분석에서는 단순 평균 비교를 넘어, 성별·연령대별 집단 차이와 비만도·생활습관에 따른 건강위험 분포를 함께 살펴보는 접근이 중요하다고 볼 수 있다.

다만 본 분석은 건강검진 데이터를 활용한 탐색적 데이터 분석으로, 변수 간 관련성과 분포 차이를 확인하는 데 목적이 있으며, 특정 생활습관이나 체격 상태가 질환을 직접 유발한다고 단정하는 해석에는 한계가 있다. 또한 이상치 처리 기준 역시 변수의 의미와 건강검진 데이터의 특성을 고려해 보수적으로 설정하였으나, 일부 기준은 의학적 진단 기준이 아니라 분석 목적에 따른 정제 기준이므로 기준 설정 방식에 따라 결과가 달라질 수 있다는 한계가 있다.

▼ 참고자료

- 질병관리청 국가건강정보포털, 「저신장」 ,
https://health.kdca.go.kr/healthinfo/biz/health/gnrlzHealthInfo/gnrlzHealthInfo/gnrlzHealthInfo\cntnts_sn=5415
- 질병관리청 국가건강정보포털, 「비만, 어떻게 관리해야 할까요?」 ,
https://health.kdca.go.kr/healthinfo/biz/health/ntcnInfo/healthSourc/thtimtCntnts/thtimtCntnts\thtimt_cntnts_sn=39
- 보건복지부, 「정상체중인데 비만이라고요? 허리둘레부터 확인하세요..」 ,
https://www.mohw.go.kr/board.es?mid=a10503010100&bid=0027&act=view&list_no=292009&tag=&nPage=854
- 질병관리청 국가건강정보포털, 「고혈압의 진단」 ,
https://health.kdca.go.kr/healthinfo/biz/health/ntcnInfo/healthSourc/thtimtCntnts/thtimtCntnts\thtimt_cntnts_sn=28
- 질병관리청 국가건강정보포털, 「운동」 ,
https://health.kdca.go.kr/healthinfo/biz/health/gnrlzHealthInfo/gnrlzHealthInfo/gnrlzHealthInfo\cntnts_sn=5293
- 질병관리청 국가건강정보포털, 「저혈압」 ,
https://health.kdca.go.kr/healthinfo/biz/health/gnrlzHealthInfo/gnrlzHealthInfo/gnrlzHealthInfo\cntnts_sn=5259
- 질병관리청 국가건강정보포털, 「당뇨병」 ,
https://health.kdca.go.kr/healthinfo/biz/health/gnrlzHealthInfo/gnrlzHealthInfo/gnrlzHealthInfo\cntnts_sn=5305
- 질병관리청 국가건강정보포털, 「당뇨환자의 약물요법」 ,
https://health.kdca.go.kr/healthinfo/biz/health/gnrlzHealthInfo/gnrlzHealthInfo/gnrlzHealthInfo\cntnts_sn=6471