

워싱턴 D.C. 자전거 대여 수요 예측 모델링 보고서

1. 모델링 목적

이번 모델링의 목적은 미국 워싱턴 D.C. 지역의 자전거 대여 데이터를 활용하여 시간대, 근무일 여부, 날씨, 기온 등의 정보를 바탕으로 총 자전거 대여량인 `count`를 예측하는 것이다.

평가 지표는 RMSLE를 사용하였다. RMSLE는 실제값과 예측값의 차이를 로그 기준으로 계산하기 때문에, 단순한 절대 오차보다 실제 수요 대비 예측값이 얼마나 비율적으로 차이 나는지를 확인하는 데 적합하다. 이번 미션에서는 검증 데이터 기준 RMSLE 0.4 이하를 목표로 모델을 개선하였다.

2. 모델링 데이터 구성

모델링에서는 총 대여량인 `count`를 예측 대상 변수로 설정하였다.

`casual`과 `registered`는 `count`를 직접 구성하는 변수이므로, 모델 입력 변수로 사용하면 데이터 누수가 발생할 수 있다. 따라서 두 변수는 모델 학습에서 제외하였다.

학습용 데이터와 검증용 데이터는 7:3 비율로 분리하였으며, 재현 가능성을 위해 `random_state=42`로 설정하였다.

3. EDA 결과를 반영한 피처 엔지니어링

EDA 결과, 자전거 대여량은 시간대, 근무일 여부, 날씨, 기온, 습도, 이용자 유형에 따라 뚜렷한 차이를 보였다. 특히 시간대별 차이가 가장 뚜렷했고, 근무일에는 출퇴근 시간대에 수요가 증가하며 비근무일에는 낮 시간대 중심으로 수요가 높게 나타났다. 또한 날씨가 좋고 기온이 높을수록 대여량이 증가하고, 습도가 높을수록 대여량이 감소하는 경향이 확인되었다.

이러한 EDA 결과를 바탕으로 모델이 대여 패턴을 더 잘 학습할 수 있도록 파생변수를 생성하였다.

EDA에서 확인한 패턴	반영한 변수
시간대별 대여량 차이	<code>hour</code> , <code>time_period</code>
출퇴근 시간대 수요 증가	<code>rush_hour</code> , <code>is_commute_time</code>
근무일/비근무일 패턴 차이	<code>workingday</code> , <code>is_weekend</code>
계절별 수요 차이	<code>month</code> , <code>season_month</code>
기온에 따른 수요 증가	<code>temp</code> , <code>temp_bin</code>
습도 증가 시 수요 감소	<code>humidity</code> , <code>humidity_bin</code>
풍속 0값의 별도 패턴 가능성	<code>windspeed_zero</code>

또한 예측 대상 변수인 `count`는 낮은 값에 많이 몰려 있고 오른쪽 꼬리가 긴 분포를 보였다. 따라서 선형회귀 모델의 성능 개선을 위해 `log1p(count)` 변환을 적용한 모델도 함께 실험하였다.

4. Baseline 모델 구축

가장 먼저 기본 모델로 선형회귀 모델을 구축하였다.

선형회귀 모델은 해석이 쉽고, 이후 다른 모델과 성능을 비교하기 위한 기준 모델로 적합하다고 판단하였다.

기본 선형회귀 모델의 RMSLE는 약 1.1253으로 나타났다. 이는 목표 기준인 0.4보다 높아, 단순 선형 모델만으로는 자전거 대여 수요를 충분히 예측하기 어렵다는 것을 확인하였다.

5. Target 로그 변환 적용

count 분포가 오른쪽으로 치우쳐 있었기 때문에, 예측 대상 변수에 log1p 변환을 적용하였다.


로그 변환은 큰 값의 영향을 완화하고, 수요가 작은 구간에서의 상대적인 오차를 줄이는 데 도움이 될 수 있다.

로그 변환을 적용한 선형회귀 모델은 기본 선형회귀 모델보다 성능이 개선되었다. 이는 자전거 대여량처럼 분포가 한쪽으로 치우친 회귀 문제에서 target 변환이 효과적일 수 있음을 보여준다.

6. 다양한 모델 비교

선형회귀 모델만으로는 비선형적인 대여 패턴을 충분히 반영하기 어렵다고 판단하여 여러 머신러닝 모델을 비교하였다.

자전거 대여 수요는 시간대, 근무일 여부, 날씨, 기온 등이 복합적으로 작용하는 문제이므로, 변수 간 비선형 관계와 상호작용을 잘 반영할 수 있는 모델이 필요하다. 이에 따라 DecisionTree, RandomForest 등 여러 회귀 모델을 비교하였다.



▲ 모델별 RMSLE 비교

model	rmsle
RandomForest	0.326923
GradientBoosting	0.387414
DecisionTree	0.441213
Lasso	0.675487
Ridge	0.676058
LinearRegression	0.676132

모델 비교 결과, RandomForest 모델이 가장 낮은 RMSLE를 기록하였다. RandomForest는 여러 개의 의사결정나무를 결합한 앙상블 모델이기 때문에, 시간대별 피크나 날씨 조건에 따른 수요 차이처럼 비선형적인 패턴을 학습하는 데 유리한 것으로 판단된다.

7. RandomForest 하이퍼파라미터 튜닝

모델 비교 결과 성능이 가장 좋았던 RandomForest 모델을 대상으로 하이퍼파라미터 튜닝을 진행하였다.

튜닝 과정에서는 트리의 개수, 최대 깊이, 분할 기준 등 모델의 복잡도와 관련된 주요 파라미터를 조정하였다. 이를 통해 과적합을 줄이면서 검증 데이터에서 더 안정적인 성능을 내는 조합을 찾고자 하였다.

튜닝 전 RandomForest 모델의 RMSLE는 약 **0.3269**였고, 튜닝 후 최종 RMSLE는 약 **0.3264**로 나타났다. 성능 개선 폭은 크지 않았지만, 튜닝 후 모델이 가장 낮은 RMSLE를 기록했기 때문에 최종 모델로 선정하였다.

8. 최종 모델 성능 비교


최종 성능 비교 결과, 기본 선형회귀 모델에서 시작해 로그 변환, 모델 변경, 하이퍼파라미터 튜닝을 거치며 RMSLE가 크게 개선되었다.

모델	RMSLE	비고
Baseline LinearRegression	1.125315	기준 모델. RMSLE가 높아 성능이 부족함
Log LinearRegression	0.676132	target 로그 변환으로 성능 개선
RandomForest	0.326923	비선형 패턴 학습으로 성능 크게 개선
Tuned RandomForest	0.326441	최종 모델. 가장 낮은 RMSLE 기록

최종 모델인 Tuned RandomForest의 RMSLE는 약 **0.3264**로, 미션 목표였던 0.4 이하를 충족하였다.

9. 변수 중요도 분석


최종 모델의 변수 중요도를 확인한 결과, hour, time_period_dawn, temp, is_commute_time, workingday 등이 주요 변수로 나타났다.



이는 EDA에서 확인한 결과와도 일치한다. 자전거 대여량은 시간대에 따라 큰 차이를 보였고, 출퇴근 시간대 및 근무일 여부에 따라 이용 패턴이 달라졌다. 또한 기온이 높을수록 대여량이 증가하는 경향이 있었기 때문에, 기온 역시 주요 변수로 작용한 것으로 해석할 수 있다.

10. 예측 오차 분석

최종 모델의 예측값과 실제값을 비교하기 위해 오차를 확인하였다. 오차는 실제값에서 예측값을 뺀 값으로 계산하였고, 절대 오차를 기준으로 모델이 크게 틀린 사례도 함께 확인하였다.



▲ 예측 오차 산점도

예측 오차 산점도를 보면 실제 대여량이 낮은 구간에서는 오차가 비교적 작게 분포했지만, 실제 대여량이 높은 구간에서는 오차의 범위가 넓어지는 경향이 나타났다. 이는 대여량이 많은 시간대일수록 수요 변동성이 커지고, 모델이 정확히 예측하기 어려운 사례가 존재한다는 것을 의미한다.

또한 일부 데이터에서는 실제값보다 크게 낮게 예측하거나, 반대로 실제값보다 높게 예측한 사례가 있었다. 이는 데이터에 포함되지 않은 이벤트, 지역적 요인, 갑작스러운 날씨 변화 등 외부 요인이 영향을 주었을 가능성이 있다.

11. 최종 모델 요약

항목	결과
최종 모델	Tuned RandomForest
최종 RMSLE	약 0.3264
기준 RMSLE	0.4 이하
기준 충족 여부	충족
주요 중요 변수	hour, time_period_dawn, temp, is_commute_time, workingday

최종 모델은 하이퍼파라미터 튜닝을 적용한 RandomForest 모델이다.

검증 데이터 기준 RMSLE는 약 0.3264로 나타났으며, 미션의 목표 기준인 0.4 이하를 충족하였다.

12. 모델 한계점 및 개선 방향

이번 모델은 전체적인 자전거 대여 수요 패턴을 예측하는 데에는 유용했지만, 몇 가지 한계도 존재한다.

첫째, 실제 대여량이 큰 구간에서는 예측 오차가 커지는 경향이 있었다. 이는 특정 이벤트, 지역별 수요 차이, 갑작스러운 날씨 변화 등 데이터에 포함되지 않은 요인이 영향을 주었을 가능성이 있다.

둘째, 이번 분석에서는 미션 요구사항에 따라 데이터를 7:3 비율로 랜덤 분리하였다. 그러나 자전거 대여 데이터는 시간 순서를 가지는 데이터이므로, 실제 서비스 예측에서는 과거 데이터를 학습하고 이후 기간을 검증하는 시간 기반 검증 방식도 고려할 필요가 있다.

셋째, 데이터가 특정 기간에 한정되어 있어 장기적인 수요 변화나 연도별 증가 효과를 충분히 검증하기에는 한계가 있다. 향후 더 긴 기간의 데이터를 활용한다면 계절성, 연도별 변화, 장기 추세를 더 안정적으로 반영할 수 있을 것이다.

13. 결론

이번 모델링에서는 자전거 대여 수요를 예측하기 위해 기본 선형회귀 모델을 시작으로 target 로그 변환, 여러 회귀 모델 비교, RandomForest 하이퍼파라미터 튜닝을 순서대로 진행하였다.

기본 선형회귀 모델의 RMSLE는 약 1.1253으로 목표 기준을 충족하지 못했지만, 로그 변환과 비선형 모델을 적용하면서 성능이 크게 개선되었다. 최종적으로 하이퍼파라미터 튜닝을 적용한 RandomForest 모델의 RMSLE는 약 0.3264로 나타났으며, 미션 목표였던 0.4 이하를 충족하였다.

변수 중요도 분석 결과, hour, time_period_dawn, temp, is_commute_time, workingday 등이 주요 변수로 나타났다. 이는 EDA에서 확인한 시간대별 수요 차이, 출퇴근 시간대 패턴, 기온의 영향이 실제 모델에서도 중요한 요인으로 작용했음을 보여준다.

따라서 최종 모델은 자전거 대여 수요의 전반적인 패턴을 예측하는 데 적합하다고 판단된다. 다만 실제 대여량이 큰 구간에서는 오차가 커지는 경향이 있었기 때문에, 향후에는 이벤트 정보, 지역 정보, 세부 날씨 정보 등을 추가로 반영하여 예측 성능을 개선할 필요가 있다.