


포르투갈 은행 정기예금 가입 패턴 EDA 보고서

1. 분석 목적

포르투갈 은행의 마케팅 캠페인 데이터를 활용해 어떤 고객이 정기예금에 가입하는지 탐색하였다. EDA에서는 금융 상태, 인구통계, 현재 캠페인 접촉 방식, 이전 캠페인 이력을 중심으로 가입률 차이를 확인하고, 이후 분류 모델에서 활용할 수 있는 후보 피처를 정리하는 데 목적을 두었다.


타겟 변수는 정기예금 가입 여부이며, 가입자보다 비가입자의 비중이 훨씬 높은 불균형 데이터이므로 단순 건수 보다 범주별 가입률과 전체 평균 대비 차이에 초점을 맞추었다.

2. 데이터 개요 및 타겟 분포




전처리 후 데이터는 45,195개의 고객 관측치와 파생변수를 포함한 39개 컬럼으로 구성되었다. 가입자는 5,289명으로 전체의 11.7%, 비가입자는 39,906 명으로 88.3%였다. 즉, 전체 정확도만 높이는 모델은 비가입자 예측에 치우칠 수 있으므로 EDA 단계부터 가입자 그룹의 특성을 따로 확인할 필요가 있다.

3. 수치형 변수 분포



▲ 수치형 변수 분포


수치형 변수 중 balance, campaign, pdays, previous 는 평균과 중앙값의 차이가 크고 한쪽으로 치우친 분포를 보였다. 특히 previous, balance, campaign 의 왜도가 크게 나타났기 때문에 단순 평균 비교만으로 해석하기보다 구간화 및 파생변수 생성이 더 적절하다.



▲ 가입 여부별 수치형 변수 비교

가입자는 비가입자보다 평균 잔고가 높고, 이전 캠페인 관련 값(pdays, previous)이 높은 반면 현재 캠페인 연락 횟수는 낮은 편이었다. 이는 이전에 반응했던 고객 또는 과도한 연락을 받지 않은 고객이 정기에금 가입 가능성이 높을 수 있음을 시사한다.


4. 금융 상태 변수별 가입 패턴



▲ 잔고 구간별 가입률, 금융 부담 그룹별 가입률

금융 상태 변수에서는 잔고 수준과 대출 부담이 가입률 차이를 분명하게 만들었다. 잔고가 high인 고객의 가입률은 약 16.6%, very_high는 약 15.5%였지만, negative_or_zero 그룹은 약 6.9%로 낮았다. 잔고가 일정 수준 이상인 고객은 예치 여력이 높아 정기에금 가입 가능성이 상대적으로 높다고 해석할 수 있다.


대출 부담이 없는 no_debt 그룹의 가입률은 약 18.4%로 가장 높았고, 주택담보대출과 개인대출을 모두 보유한 housing_and_loan 그룹은 약 6.1%로 가장 낮았다. 단일 대출 여부보다 주택담보대출과 개인대출을 결합한 금융 부담 그룹이 가입률 차이를 더 선명하게 보여준다.




▲ 주택담보대출 여부별 가입률, 개인대출 여부별 가입률

주택담보대출이 없는 고객의 가입률은 약 16.7%, 보유 고객은 약 7.7%였고, 개인대출이 없는 고객은 약 12.7%, 보유 고객은 약 6.7%였다. 정기에금 상품은 여유 자금과 관련이 크기 때문에 금융 부담이 낮은 고객을 우선 세그먼트로 고려할 수 있다.

5. 인구통계 변수별 가입 패턴



▲ 나이대별 가입률, 직업별 가입률




▲ 교육 수준별 가입률, 생애단계별 가입률

인구통계 변수에서는 연령과 직업의 차이가 뚜렷했다. 70 대 이상 고객의 가입률은 약 42.4%, 60 대는 약 29.7%로 높았고, 30~50 대 고객은 상대적으로 낮았다. 이는 나이와 가입률이 단순 선형 관계가 아니라 청년층과 고령층에서 높아지는 U자형 패턴에 가깝다는 점을 보여준다.

직업별로는 student 가 약 28.7%, retired 가 약 22.8%, unemployed 가 약 15.5%로 높았고, blue-collar 와 entrepreneur 는 낮았다. 생애 단계 변수로 묶어 보아도 student, senior, retired 그룹의 가입률이 높고 일반 경제 활동층은 약 9.8%로 낮았다.


6. 현재 캠페인 관련 가입 패턴



▲ 연락 수단별 가입률, 연락 월별 가입률

현재 캠페인 변수에서는 연락 수단과 연락 횟수가 중요했다. 휴대전화와 유선전화로 연락한 고객의 가입률은 13~15% 수준이었지만, 연락 수단이 unknown 인 경우 가입률은 약 4.1%로 매우 낮았다. 따라서 contact 의 unknown 은 단순 결측이 아니라 가입 가능성이 낮은 상태를 나타내는 정보로 보는 편이 적절하다.


월별 가입률은 3 월, 12 월, 9 월, 10 월에서 높았으나 해당 월들은 고객 수가 작을 수 있다. 반대로 5 월은 고객 수가 가장 많았지만 가입률이 약 6.7%로 낮았다. 월 변수는 캠페인 운영 시점이나 고객군 차이가 섞여 있을 가능성이 있으므로 표본 수와 함께 해석해야 한다.



▲ 분기별 가입률, 현재 캠페인 연락 횟수 구간별 가입률


현재 캠페인 연락 횟수는 가입률과 음의 관계를 보였다. 1 회 연락 고객의 가입률은 약 14.6%였지만, 11 회 이상 연락한 고객은 약 3.9%였다. 6 회 이상 연락한 고객의 가입률도 약 5.8%로 낮아, 반복 연락은 설득 효과라기보다 미가입 가능성이 높은 고객에게 더 많이 연락했을 가능성을 보여준다.

7. 이전 캠페인 이력 관련 가입 패턴



▲ 이전 연락 여부별 가입률, 이전 캠페인 결과별 가입률


이전 캠페인 이력은 이번 EDA 에서 가장 강한 가입 신호로 나타났다. 이전 연락 이력이 있는 고객의 가입률은 약 23.1%로, 이전 연락 이력이 없는 고객의 약 9.2%보다 훨씬 높았다. 특히 이전 캠페인 결과가 success 였던 고객의 가입률은 약 64.7%로 매우 높았다. 반면 poutcome이 unknown 인 고객은 대부분 이전 캠페인 이력이 없는 고객으로 해석되며 가입률도 약 9.2%에 머물렀다. 따라서 poutcome 은 모델링에서 핵심 피쳐 후보로 볼 수 있다.



▲ 이전 연락 후 경과일 구간별 가입률, 이전 연락 횟수 구간별 가입률

이전 연락 후 31~90 일이 지난 고객의 가입률은 약 42.1%로 높았고, 91~180 일 및 365 일 초과 그룹도 전체 평균보다 높았다. 또한 previous 가 0 회인 고객은 가입률이 낮았지만, 이전 연락 횟수가 1 회 이상인 고객은 대체로 21% 이상의 가입률을 보였다.


8. 수치형 변수 상관관계



▲ 수치형 변수 상관관계 히트맵


상관관계에서는 was_previous_success, has_previous_contact, pdays, previous 가 타겟과 양의 관계를 보였고, housing_num, loan_count, campaign 은 음의 관계를 보였다. 이는 이전 캠페인 반응 이력은 긍정 신호, 대출 부담과 과도한 현재 연락은 부정 신호라는 앞선 EDA 해석과 일치한다.

9. 두 변수 조합별 가입 패턴



▲ 나이대 × 잔고 구간 가입률, 주택담보대출 × 개인대출 가입률

단일 변수별 가입률뿐 아니라 변수 조합에서도 의미 있는 차이가 확인되었다. 특히 연령대와 잔고를 함께 보면 고령층일수록, 그리고 잔고가 높을수록 가입률이 높아졌다. 70 대 이상이면서 high 잔고 그룹은 약 46.6%, very_high 그룹은 약 41.8%로 높았다.



▲ 캠페인 구간 × 연락 수단 가입률, 이전 캠페인 결과 × 현재 연락 수단 가입률

현재 캠페인에서는 cellular/telephone 모두 1 회 연락 구간의 가입률이 가장 높고, 연락 횟수가 늘어날수록 낮아졌다. 이전 캠페인이 성공한 고객은 현재 연락 수단과 관계없이 가입률이 높았지만, 현재 연락 수단이 unknown 인 경우에는 이전 성공 이력이 있어도 가입률이 상대적으로 낮았다.

10. 모델링 관점의 핵심 피쳐 후보

변수	최고 가입률	최저 가입률	격차	해석
poutcome	64.7%	9.2%	55.6%p	이전 캠페인 성공 여부가 가장 강한 신호
month	52.0%	6.7%	45.3%p	월별 성과 차이는 크지만 표본 수 확인 필요
age_group	42.4%	9.1%	33.3%p	고령층과 청년층에서 가입률 높음
pdays_group	42.1%	9.2%	32.9%p	이전 연락 시점이 가입률 차이를 설명
job	28.7%	7.3%	21.4%p	student/retired 와 bluecollar 차이 큼
debt_group	18.4%	6.1%	12.3%p	금융 부담이 낮을수록 가입 가능성 높음

범주별 최고 가입률과 최저 가입률의 차이를 기준으로 보면 poutcome, month, age_group, pdays_group, job, life_stage 가 큰 가입률 격차를 보였다. 다만 month 처럼 표본 수가 작은 범주가 포함된 변수는 단순 가입률만으로 판단하기보다 고객 수와 함께 해석해야 한다.

가입자와 비가입자의 구성 비율 차이를 보면 housing, contact, debt_group, poutcome 의 차이가 컸다. 가입자 집단에서는 no_debt, cellular, success 의 비중이 상대적으로 높았고, housing_only, contact unknown, poutcome unknown 의 비중은 낮았다.

11. 결론

정기예금 가입 가능성은 단일 변수로 설명되기보다 금융 여력, 생애단계, 현재 캠페인 접촉 방식, 이전 캠페인 반응 이력이 함께 작용하는 패턴을 보였다. 특히 이전 캠페인 성공 여부와 이전 연락 이력은 가장 강한 긍정 신호였고, 대출 부담과 과도한 현재 연락, 연락 수단 unknown 은 부정 신호로 나타났다.

따라서 이후 모델링에서는 poutcome, pdays_group, previous_group, contact, campaign_group, debt_group, balance_group, age_group, job, life_stage 등을 주요 피쳐 후보로 활용하는 것이 타당하다. 또한 가입자 비중이 낮은 불균형 데이터이므로 전체 Accuracy 만 보기보다 가입자 F1-score 와 재현율을 함께 확인하면 서 모델을 개선해야 한다.