

정기예금 가입 예측 모델링 및 성능 평가 보고서

구분	내용
최종 모델	LightGBM Weight + Threshold
핵심 설정	class_weight={0:1, 1:2.5}, threshold=0.47
최종 성능	Accuracy 0.8824 / 가입자 F1-score 0.4838
선정 이유	심화 기준인 Accuracy ≥ 0.88 , 가입자 F1-score ≥ 0.45 를 충족한 후보 중 가입자 F1-score가 가장 높음

1. 분석 목적과 평가 방향

본 모델링의 목적은 고객 정보와 캠페인 이력 데이터를 활용해 정기예금 가입 여부(y)를 예측하는 것이다. 타깃 변수는 가입 여부인 no/yes로 구성되어 있으며, 가입자는 전체의 약 11.7%에 불과해 클래스 불균형이 뚜렷하게 나타났다. 따라서 단순히 전체 정답률인 Accuracy만으로 모델을 선택할 경우, 대부분의 고객을 비가입자로 예측해도 높은 성능처럼 보일 수 있다. 이에 따라 본 모델링에서는 전체 예측 안정성과 함께 가입자 클래스의 Precision, Recall, F1-score를 함께 평가하였다.

- Accuracy는 전체 예측 안정성을 확인하는 지표로 사용했다.
- 가입자 F1-score는 가입자를 얼마나 균형 있게 탐지하는지 판단하는 핵심 지표로 사용했다.
- 최종 모델 선정 기준은 Accuracy 0.88 이상, 가입자 F1-score 0.45 이상으로 설정했다.


2. 모델링 설계

모델링은 학습/테스트 분리, 전처리 파이프라인 구성, 기준 모델 설정, 불균형 보정, 모델 확장, threshold 튜닝 순서로 진행했다. 특히 테스트 데이터는 최종 성능 확인에만 사용하고, threshold 선택은 학습 데이터 내부의 validation set에서 수행하여 테스트셋 기준 과적합을 줄이고자 했다.

단계	수행 내용	의미
데이터 분리	train/test = 70:30, stratify=y 적용	가입/미가입 비율을 유지한 상태로 평가 데이터 확보
전처리	수치형: 중앙값 대체 + 표준화 / 범주형: 최빈값 대체 + One-Hot Encoding	모든 모델에 동일한 전처리 기준 적용
기준 모델	Logistic Regression	Accuracy는 높지만 가입자 탐지력이 낮은 기준선 확인
불균형 보정	class_weight, sample_weight, SMOTE, scale_pos_weight	소수 클래스인 가입자 탐지력 개선 시도
모델 확장	Decision Tree, Random Forest, Extra Trees, Gradient Boosting, XGBoost, LightGBM, CatBoost	단순 모델부터 앙상블/부스팅 계열까지 성능 비교
Threshold 조정	validation set에서 threshold 후보 탐색	Accuracy와 가입자 F1-score의 균형점 탐색
최종 선택	LightGBM Weight + Threshold	심화 기준을 만족하면서 성능 균형이 가장 좋음

3. 모델 실험 결과 비교

초기 모델에서는 Logistic Regression 과 Gradient Boosting 의 Accuracy 가 약 0.89 로 높았지만, 가입자 F1-score 가 0.28~0.30 수준에 머물렀다. 이는 대부분을 비가입자로 예측해도 Accuracy 가 높게 나오는 불균형 데이터의 전형적인 문제이다. 이후 class_weight, threshold 조정, 고급 부스팅 모델을 적용하면서 가입자 탐지 성능을 단계적으로 개선했다.




모델	Accuracy	가입자 Precision	가입자 Recall	가입자 F1	Threshold	XGB 가중치	yes 가중치
CatBoost	0.8795	0.4857	0.5022	0.4938	0.3100	-	1.5000
LightGBM Final	0.8824	0.4977	0.4707	0.4838	0.4700	-	2.5000
Tuned RF	0.8661	0.4401	0.5299	0.4808	-	-	-
Soft Voting	0.8795	0.4846	0.4663	0.4753	0.3100	-	-
XGBoost Tuned	0.8810	0.4912	0.4581	0.4741	0.3300	1.5000	-
Tuned RF Fine Threshold	0.8779	0.4769	0.4480	0.4620	0.6050	-	-

최종 후보 관점에서 보면 CatBoost는 가입자 F1-score가 가장 높았지만, Accuracy가 0.8795로 심화 기준인 0.88에 미달했다. XGBoost는 Accuracy 기준을 만족했으나 LightGBM보다 가입자 F1-score가 낮았다. 따라서 Accuracy 0.8824와 가입자 F1-score 0.4838을 동시에 달성한 LightGBM Weight + Threshold 모델을 최종 모델로 선정했다.

4. 최종 모델 성능 평가

최종 모델은 LightGBM에 가입자 클래스 가중치 2.5를 적용하고, validation set에서 선택한 threshold 0.47을 사용했다. 최종 평가는 독립적인 test set 13,559건에서 수행했다.




지표	값
Accuracy	0.8824
가입자 Precision	0.4977
가입자 Recall	0.4707
가입자 F1-score	0.4838
비가입자 F1-score	0.9337
Macro F1	0.7087
Weighted F1	0.8810

최종 모델은 전체 정확도 0.8824 를 유지하면서 가입자 F1-score 0.4838 을 달성했다. 가입자 precision 은 약 0.498, recall 은 약 0.471 로, 가입자를 예측한 고객 중 절반 정도가 실제 가입자였고 실제 가입자 중 약 47.1%를 탐지했다. 불균형 데이터에서 비가입자 예측 안정성을 크게 훼손하지 않으면서 가입자 탐지 성능을 개선한 결과로 볼 수 있다.

5. 예측 결과와 오차 해석


최종 모델의 예측 결과를 Confusion Matrix로 확인했다.



Actual	예측 no	예측 yes	정답률/탐지율
실제 no	11,218	754	93.7%
실제 yes	840	747	47.1%

- 비가입자 11,972명 중 11,218명을 비가입자로 맞췄고, 754명은 가입자로 잘못 예측했다.
- 가입자 1,587명 중 747명을 가입자로 맞췄고, 840명은 비가입자로 잘못 예측했다.
- 비가입자 오탐율은 약 6.3%로 낮은 편이지만, 가입자 미탐지율은 약 52.9%로 추가 개선 여지가 있다.

즉, 최종 모델은 전체적으로 안정적인 예측 성능을 보였지만, 실제 가입자를 놓치는 False Negative가 여전히 존재한다. 정기예금 캠페인에서는 실제 가입 가능성이 있는 고객을 놓치는 것이 중요한 기회 손실로 이어질 수 있으므로, 향후에는 가입자 미탐지를 줄이는 방향의 개선이 필요하다.




전체 테스트 데이터 13,559건 중 오분류는 1,594건으로, 오분류율은 약 11.8%였다. 오분류 중 False Negative는 840건(52.7%), False Positive는 754건(47.3%)으로 나타났다.

오분류 중에서는 가입자를 비가입자로 예측한 False Negative가 조금 더 많았다. 따라서 향후 모델 개선은 가입자 미탐지를 줄이되, 비가입자 오탐이 급격히 늘지 않도록 threshold와 비용 기준을 함께 조정하는 방향이 적절하다.

6. 변수 중요도 해석

최종 LightGBM 모델의 변수 중요도를 원본 변수 단위로 집계해 확인했다. One-Hot Encoding으로 파생된 변수들은 원본 변수 기준으로 묶어 중요도를 합산했다.



최종 모델의 변수 중요도는 balance, age, day, campaign, month, pdays, job 순으로 높게 나타났다. 이는 고객의 잔고와 연령, 캠페인 접촉 시점, 연락 횟수, 과거 캠페인 이력이 정기예금 가입 예측에 중요한 정보로 활용되었음을 의미한다. EDA에서 확인했던 캠페인 관련 변수와 고객의 재무/인구통계 변수의 차이가 모델에서도 주요한 예측 신호로 반영되었다.

특히 balance와 age가 가장 높은 중요도를 보였다는 점은, 정기예금 가입 여부가 고객의 재무 상태와 생애주기적 특성에 영향을 받을 가능성이 있음을 시사한다. 또한 campaign, month, day, pdays와 같은 캠페인 관련 변수들이 상위권에 위치해, 캠페인 접촉 방식과 시점 역시 가입 예측에 중요한 요소로 작용했음을 확인할 수 있다.

7. 오차 패턴 및 개선 방향

모델의 오차를 단순히 전체 성능으로만 확인하지 않고, 어떤 고객군에서 가입자를 놓치는지 살펴보았다. 이를 통해 향후 모델 개선과 캠페인 운영 전략에 활용할 수 있는 방향을 정리했다.

관점	관찰 결과	개선 방향
직업군	blue-collar, entrepreneur, housemaid 등에서 가입자 미탐지율이 높음	해당 직군의 가입 패턴을 별도로 분석하거나 세그먼트별 threshold 검토
연락 채널	contact가 unknown인 실제 가입자는 미탐지율이 매우 높음	연락 채널 정보 보완 또는 unknown 그룹 별도 처리
대출/주택담보	housing=yes, loan=yes 그룹에서 실제 가입자를 놓치는 비율이 높음	금융 부담 변수를 더 세분화해 가입 여력/관심도 신호 추가
월/캠페인 시점	month와 campaign 관련 변수가 중요도 상위권에 위치	캠페인 시점별 반응 차이를 반영한 운영 전략 수립

오차 분석 결과, 특정 직업군과 연락 채널 정보가 불명확한 고객군에서 실제 가입자를 놓치는 문제가 확인되었다. 또한 주택담보대출이나 개인 대출 여부와 같은 금융 부담 변수에서도 미탐지 패턴이 나타났다. 따라서 향후에는 전체 고객에게 동일한 threshold를 적용하기보다, 고객 세그먼트별로 가입 가능성과 오탐 비용을 다르게 고려하는 방식이 필요하다. 예를 들어 특정 직업군이나 연락 채널 unknown 그룹에 대해서는 별도의 threshold를 적용하거나, 해당 고객군의 행동 패턴을 추가적으로 분석할 수 있다.

8. 최종 결론

이번 모델링은 불균형 데이터에서 단순 Accuracy 중심 평가의 한계를 확인하고, 가입자 F1-score 를 함께 개선하는 방향으로 진행되었다. 기준 모델은 높은 Accuracy 에도 가입자를 대부분 놓치는 문제가 있었고, class_weight 와 threshold 조정, 앙상블/부스팅 모델 비교를 통해 가입자 탐지 성능을 개선했다. 최종적으로 LightGBM Weight + Threshold 모델은 Accuracy 0.8824, 가입자 F1-score 0.4838 을 기록해 심화 기준을 충족했다.