

신용카드 고객 세그멘테이션 모델링 보고서

프로젝트: 스프린트 미션 13

분석일: 2026-09-14

분석 단위: 고객 1명당 1행

최종안: `log1p` → `RobustScaler` → `PCA(90%)` → `k-means(k=5)`


1. Executive summary

이 분석은 8,950명의 신용카드 이용 정보를 바탕으로 마케팅 실행에 사용할 고객 세그먼트를 설계했다. 원본 수치에 표준화만 적용한 k-means는 극단값과 강한 오른쪽 왜도의 영향을 크게 받았다. 금액·거래횟수 10개 변수에 `log1p` 변환을 적용하고, 중앙값과 IQR에 기반한 Robust scaling으로 이상치 민감도를 낮춘 뒤 PCA로 17개 변수를 6개 축으로 축소했다. 이 6개 축은 전체 분산의 90.7%를 보존한다.

수치상 실루엣 최고점은 $k=3(0.435)$ 이지만, 최대 군집이 71.5%를 차지해 마케팅 실행 단위로 지나치게 거칠다. $k=5$ 는 실루엣 0.322, Davies-Bouldin 1.016, 최대 군집 41.9%, 최소 군집 6.6%로 분리도와 실행 가능성의 균형이 더 낫다. 80% 재표본 20회에서 전체 고객 예측의 ARI 평균이 0.995로 나타나 결과 재현성도 높았다.

최종 세그먼트는 우량 전액결제 해비유저, 생활결제 잔액유지형, 현금서비스 의존형, 신규·단기 현금서비스형, 저활동 잠재휴면형의 5개다. 이 보고서는 모델 선택의 근거를 다루며, 세부 고객 전략은 별도 세그먼트 보고서에서 제시한다.

데이터 품질 진단



2. 분석 목표와 의사결정 원칙

2.1 비즈니스 질문

1. 구매, 현금서비스, 잔액, 상환 행동이 유사한 고객 집단은 무엇인가?
2. 각 집단은 충분히 크고 구분되어 개별 캠페인으로 운영할 수 있는가?
3. 새 표본이나 초기값 변화에도 세그먼트가 유지되는가?
4. 군집을 마케팅 언어로 해석하고 행동 전략으로 연결할 수 있는가?

2.2 선정 기준

기준	사용 지표	판단 방식
군집 내 응집·군집 간 분리	Silhouette	높을수록 우수
군집 간 중첩	Davies-Bouldin	낮을수록 우수
분산 대비 분리	Calinski-Harabasz	높을수록 우수
운영 가능성	최소·최대 군집 비중	과도한 쏠림과 지나친 소군집 회피
재현성	재표본 ARI	동일 고객 배정이 안정적인지 확인
해석 가능성	원단위 프로파일	실제 캠페인으로 번역 가능한지 검토

실루엣 하나만 최대화하지 않았다. 군집 수가 적으면 지표는 좋아지기 쉽지만 고객 행동 차이가 합쳐져 실행력이 떨어질 수 있다. 반대로 군집 수가 많으면 경계가 불안정하고 운영비가 증가한다.

3. 데이터 감사

3.1 구조와 무결성


항목	결과
행 수	8,950
전체 컬럼 수	18
모델 입력 변수	17
<code>CUST_ID</code> 중복	0
완전 중복 행	0
<code>MINIMUM_PAYMENTS</code> 결측	313 (3.50%)
<code>CREDIT_LIMIT</code> 결측	1 (0.01%)

식별자인 `CUST_ID` 는 모델에서 제외했다. 결측치는 삭제하지 않고 각 변수의 중앙값으로 대체했다. 고객 313명을 제거하면 특정 상환행동 고객이 체계적으로 빠질 수 있고, 평균 대체는 극단값의 영향을 받기 때문이다. 결측 여부 자체가 위험 신호인지 확인할 외부 데이터가 없으므로 별도 결측 플래그는 최종 군집 입력에서 제외했다.


3.2 분포 핵심

- `MINIMUM_PAYMENTS` 왜도 13.62, `ONEOFF_PURCHASES` 10.05, `PURCHASES` 8.14로 긴 오른쪽 꼬리가 강하다.
- `ONEOFF_PURCHASES` , `INSTALLMENTS_PURCHASES` , `CASH_ADVANCE` 에는 0이 많다. 이는 단순 결측이 아니라 해당 행동을 하지 않은 고객이라는 유효한 신호다.
- 구매액과 구매횟수, 현금서비스 금액과 횟수처럼 중복 정보가 강한 변수군이 있다. PCA는 이 상관 구조를 압축하고 거리 계산에서 중복 가중을 줄인다.

핵심 금액 변수 분포: 극단적 오른쪽 꼬리를 로그 변환으로 완화



변수 간 순위상관: 구매-빈도 변수의 중복 정보 확인



4. 전처리 설계


4.1 적용 순서

1. `CUST_ID` 제외
2. `CREDIT_LIMIT`, `MINIMUM_PAYMENTS` 결측을 변수별 중앙값으로 대체
3. 금액·거래횟수 10개 변수에 `log1p` 적용
4. 모든 변수에 `RobustScaler` 적용
5. PCA 누적 설명분산 90% 기준 적용: 17개 → 6개 주성분

`log1p` 는 0을 보존하면서 큰 금액 간 거리 폭주를 줄인다. `RobustScaler`는 중앙값과 IQR을 사용해 이상치의 영향을 추가로 줄인다. 빈도 변수는 0~1 범위의 의미가 있으므로 로그 변환하지 않고 스케일링만 했다.

4.2 전처리 실험 결과

동일한 k-means와 랜덤 시드를 사용해 원본 표준화, 원저화, 로그 변환, Robust scaling, PCA 90%·95% 조합을 비교했다. k=5에서 원본+표준화 실루엣은 0.188, 최종 조합은 0.322로 개선됐다. PCA 95%보다 90%가 더 좋은 결과를 보인 것은 설명력이 낮은 축의 잡음이 거리 계산에 다시 유입될 수 있음을 보여준다.



5. 군집 수 선택


5.1 k=3과 k=5의 trade-off

지표	k=3	k=5	해석
Silhouette	0.435	0.322	k=3 우위
Davies-Bouldin	0.960	1.016	k=3 우위
최대 군집 비중	71.5%	41.9%	k=5가 쏠림 완화
최소 군집 비중	13.8%	6.6%	두 안 모두 캠페인 규모 확보
행동 해상도	낮음	높음	k=5에서 현금서비스 고객의 신규/기존 분리 가능

k=5는 수치상 절대 최고점이 아니라, 서로 다른 개입이 필요한 고객을 분리하는 운영 해상도를 얻기 위한 선택이다. 특히 장기 현금서비스 의존 고객과 보유기간이 짧은 초기 현금서비스 고객은 메시지, 채널, 위험관리 방식이 달라야

한다.

k=3은 수치 최적, k=5는 마케팅 실행력까지 포함한 운영 최적




6. 알고리즘 비교

k-means 외에 Gaussian Mixture Model과 Birch를 동일한 PCA 공간에서 비교했다. GMM-tied k=3은 높은 실루엣을 보였지만 한 군집이 약 75%에 가까워 고객 대부분을 하나의 덩어리로 묶었다. GMM-tied k=5도 최대 군집 비중이 약 69%, 최소 군집이 약 3%로 쓸림이 컸다. Birch는 대용량 확장성은 좋지만 현재 데이터에서는 분리도와 균형이 모두 k-means보다 약했다.

최종적으로 k-means를 선택한 이유는 다음과 같다.

- 5개 세그먼트가 모두 캠페인 운영 가능한 크기다.
- 중심점과 거리 기반 설명이 쉬워 고객 배정 규칙을 관리하기 좋다.
- 80% 재표본 반복에서 높은 일치도를 보였다.
- GMM의 소프트 확률은 유용하지만 현재 결과는 군집 크기 쓸림이 커서 주 모델보다 보조 불확실성 지표에 적합하다.

알고리즘 비교: 높은 실루엣만으로는 실행 가능한 세분화가 보장되지 않음



7. 최종 모델과 검증

7.1 최종 성능


항목	값
PCA 설명분산	90.7%
PCA 주성분 수	6
Silhouette	0.322
Calinski-Harabasz	4,055
Davies-Bouldin	1.016
재표본 ARI 평균	0.995
재표본 ARI 범위	0.988~0.998



7.2 안정성 검증

원자료의 80%를 비복원 추출해 k-means를 다시 학습하고 전체 고객을 예측하는 과정을 20회 반복했다. 기준 모델과의 ARI 평균은 0.995, 최솟값은 0.988였다. 군집 번호 순서와 무관하게 거의 동일한 고객끼리 묶였다는 뜻이다.

개별 고객 수준에서는 실루엣과 최근접·차근접 중심 간 거리 마진을 함께 저장하도록 설계했다. 경계 고객은 공격적 개인화 대신 일반 캠페인 또는 검증용 홀드아웃으로 처리해야 한다.

PCA: 17개 변수에서 6개 축으로 축소하며 90.7% 정보 유지





8. 재현성과 운영화

노트북은 데이터 로드부터 EDA, 전처리 비교, 알고리즘 비교, 안정성 평가, 최종 프로파일, 고객별 결과 내보내기까지 순서대로 실행된다. Colab에서는 `credit_card.csv` 를 업로드하면 실행되며, 마지막 셀은 다음 파일을 만든다.

- `mission13_customer_segments.csv` : 고객별 세그먼트, 개별 실루엣, 중심 거리 마진
- `mission13_model_bundle.joblib` : imputer, scaler, PCA, k-means, 변수 목록, 세그먼트 매핑
- `mission13_segment_profile.csv` : 세그먼트별 원단위 평균 프로파일

운영 환경에서는 월별로 분포 변화와 세그먼트 비중을 모니터링하고, 기준을 넘는 drift가 발생했을 때만 재학습해야 한다. 무조건 매월 재학습하면 세그먼트 의미가 흔들려 캠페인 성과 비교가 어려워진다.

권장 모니터링:

영역	지표	권장 경보 기준
입력 분포	PSI	주요 변수 PSI > 0.20 검토
세그먼트 구성	월별 비중 변화	절대 5%p 이상 변화 검토
배정 품질	평균 실루엣-거리 마진	기준 대비 20% 이상 악화 검토
캠페인 가치	세그먼트별 증분 반응	통제군 대비 uplift와 수익 동시 확인

9. 한계와 해석 주의

1. 정답 라벨이 없는 비지도학습이므로 실루엣은 “진짜 고객 유형”을 증명하지 않는다.
2. 데이터는 집계 스냅샷이며 거래 시점, 상품, 연체, 수익, 인구통계 정보가 없다. 인과적 마케팅 효과를 직접 추정할 수 없다.
3. 금액의 통화와 집계 기간이 명시되지 않아 절대 금액보다 세그먼트 간 상대 비교가 안전하다.
4. **TENURE**가 짧은 고객은 관측 기간 자체가 짧아 총액이 낮게 보일 수 있다. 캠페인 집행 시 월평균 보정 지표를 추가 검토해야 한다.
5. 현금서비스 관련 세그먼트는 마케팅보다 신용·소비자보호 정책을 우선해야 한다.

10. 결론

최종 k=5 모델은 수치 최대화와 마케팅 실행 사이의 균형을 택했다. 전처리를 통해 k=5 실루엣을 0.188에서 0.322로 높였고, 6개 PCA 축에서 90.7%의 정보를 유지했다. 재표본 ARI 0.995는 결과가 표본 변화에 매우 안정적임을 보여준다. 다음 단계는 세그먼트별 캠페인을 무작위 통제 실험으로 검증해 “분류가 다르다”를 “행동 반응이 다르다”로 전환하는 것이다.