

미션14_팀명_성함_보고서

SNS 텍스트 감정 분석 및 분류 모델 보고서

프로젝트: 스프린트 미션 14

분석일: 2026-09-16

최종 모델: Word TF-IDF + Character TF-IDF + class-balanced Linear SVM

주 평가 기준: Macro F1, 보조 기준: Accuracy


1. Executive summary

학습 17,948건과 테스트 2,000건의 영문 SNS 텍스트를 여섯 감정으로 분류했다. 결측, 중복, 학습-테스트 간 동일 문장 중복이 없어 기본 데이터 무결성이 양호했다. 다만 surprise는 학습셋의 3.6%, love는 8.2%에 불과해 정확도만으로는 성능을 과대평가할 수 있다.

워드클라우드를 분류용 전처리와 분리했다. 시각화에서는 명사·동사·형용사·부사만 유지하고 표제어 추출, 일반 불용어와 **feel**, **feeling**, **really** 같은 코퍼스 공통어 제거, 감정 대 나머지의 chi-square와 log-lift를 결합했다. 그 결과 단순 빈도 워드클라우드보다 감정 차이가 선명해졌다.

모델 선택은 테스트셋을 반복해 보지 않고 학습셋 3-fold 교차검증으로 수행했다. 기준 Logistic Regression의 Macro F1 0.855에서 단어 1-2gram과 문자 3-5gram TF-IDF를 결합한 Linear SVM 0.863으로 개선했다. 최종 테스트 정확도는 89.7%, Macro F1은 0.856이다. surprise를 제외한 긍정·부정 이진 분류는 정확도 97.8%, Macro F1 0.978, ROC-AUC 0.997를 기록했다.


데이터 감사



2. 데이터 감사

항목	학습셋	테스트셋
행 수	17,948	2,000
결측값	0	0
정규화 후 중복 문장	0	0
학습-테스트 동일 문장	-	0
평균 단어 수	19.1	19.2
단어 수 중앙값	17	17

라벨 비중과 텍스트 길이 분포가 학습-테스트에서 유사해 큰 분포 이동은 보이지 않는다. exact overlap이 0이므로 동일 문장 양기로 인한 테스트 누수도 확인되지 않았다.



3. 전처리 전략

3.1 분류용 전처리

분류 모델에는 과도한 정제를 적용하지 않았다.

1. 소문자화
2. URL과 사용자명 치환
3. 해시태그 기호만 제거하고 단어는 보존
4. 영문자와 apostrophe 외 문장부호 제거
5. 연속 공백 정리

불용어 제거와 품사 제한을 분류 입력에 적용하지 않은 이유는 `not`, 대명사, 조동사, 짧은 연결 표현도 감정 방향과 문맥을 전달할 수 있기 때문이다. 문자 n-gram은 `im`, `dont`, `didnt` 같은 비표준 축약과 철자 변형에 강하다.

3.2 워드클라우드용 전처리

워드클라우드를 사람이 읽는 설명 도구이므로 더 공격적인 정제를 적용했다.

1. 명사·동사·형용사·부사만 유지
2. WordNet 표제어 추출
3. 영어 일반 불용어 제거
4. 모든 감정에서 반복되는 `feel`, `feeling`, `really`, `like` 등 제거
5. 감정 대 나머지의 chi-square와 양의 log-lift 결합

단순 빈도는 "데이터에 많이 나온 단어"를 보여준다. 정제 방식은 "해당 감정을 다른 감정과 구분하는 단어"를 보여준다.

원시 빈도 워드클라우드: 공통 표현이 감정 차이를 가림



정제 워드클라우드: 품사·표제어·감정 특이도 반영




4. 감정별 판별 단어

순위	sadness	joy	love	anger	fear	surprise
1	gloomy	festive	sympathetic	resentful	apprehensive	curious
2	inadequate	energetic	horny	greedy	vulnerable	impressed
3	unimportant	superior	loyal	irritable	reluctant	amaze
4	melancholy	clever	nostalgic	dangerous	shaky	funny
5	punish	intelligent	tender	bitchy	hesitant	daze
6	unwelcome	content	fond	cranky	uncertain	impress
7	listless	successful	naughty	rebellious	unsure	surprised
8	groggy	artistic	supportive	violent	paranoid	shock

워드클라우드 크기는 전체 빈도가 아니라 감정 특이도 점수에 비례한다. 따라서 큰 단어는 해당 감정에서 절대적으로 가장 많은 단어가 아니라, 다른 감정보다 상대적으로 더 강하게 나타나는 단어다.

감정별 판별 단어



5. 모델 개선 과정

5.1 평가 설계


- 모델 선택: 학습셋 내부 Stratified 3-fold 교차검증
- 1차 지표: Macro F1
- 보조 지표: Accuracy
- 최종 평가: 모델 선택 완료 후 테스트셋 1회
- 클래스 불균형 대응: `class_weight='balanced'`

5.2 교차검증 결과

모델	CV Accuracy	CV Macro F1	Fold 표준편차
Hybrid word+char TF-IDF + Linear SVM	0.895	0.863	±0.003
TF-IDF word 1-2gram + Linear SVM	0.889	0.856	±0.002
Baseline Count unigram + Logistic Regression	0.887	0.855	±0.002
TF-IDF word 1-2gram + Logistic Regression	0.877	0.846	±0.006
TF-IDF char 3-5gram + Linear SVM	0.874	0.841	±0.004
TF-IDF word 1-2gram + ComplementNB	0.871	0.834	±0.002
POS content words only + Linear SVM	0.857	0.822	±0.006

TF-IDF로 바꾸는 것만으로 성능이 항상 오르는 않았다. 모델과 특성 표현의 궁합이 중요했다. 문자 TF-IDF 단독은 단어 의미를 충분히 담지 못했지만, 단어 TF-IDF와 결합했을 때 축약·철자 변형을 보완했다. 품사 제한 입력은 워드클라우드에는 유용했지만 분류에서는 문맥 정보가 줄어 최종 선택에서 제외했다.

Random Forest는 고차원 희소 텍스트에서 메모리 사용이 크고 선형 모델보다 효율이 낮아 최종 후보에서 제외했다. Linear SVM은 수십만 개의 희소 n-gram에 적합하고, 작은 클래스까지 고려한 Macro F1이 가장 높았다.



6. 최종 6-class 테스트 성능

지표	값
Accuracy	0.897
Macro F1	0.856
Weighted F1	0.898

감정	Support	Precision	Recall	F1
sadness	581	0.950	0.923	0.936
joy	695	0.927	0.919	0.923
love	159	0.751	0.836	0.792
anger	275	0.866	0.895	0.880
fear	224	0.891	0.839	0.864
surprise	66	0.693	0.788	0.738

sadness와 joy는 0.92 이상의 F1을 기록한다. love와 surprise는 표본이 적고 각각 joy, fear와 의미적으로 가까워 상대적으로 어렵다. 가장 큰 단일 오분류 방향은 joy → love 40건이다.


최종 6-class 테스트 혼동행렬

		건수								행 기준 비율					
실제	sadness	536	14	2	20	8	1	실제	sadness	92.3%	2.4%	0.3%	3.4%	1.4%	0.2%
	joy	3	639	40	4	2	7		joy	0.4%	91.9%	5.8%	0.6%	0.3%	1.0%
	love	0	21	133	3	0	2		love	0.0%	13.2%	83.6%	1.9%	0.0%	1.3%
	anger	13	6	2	246	7	1		anger	4.7%	2.2%	0.7%	89.5%	2.5%	0.4%
	fear	10	5	0	9	188	12		fear	4.5%	2.2%	0.0%	4.0%	83.9%	5.4%
	surprise	2	4	0	2	6	52		surprise	3.0%	6.1%	0.0%	3.0%	9.1%	78.8%
		sadness	joy	love	anger	fear	surprise			sadness	joy	love	anger	fear	surprise
		예측								예측					

7. 모델 해석

최종 Linear SVM의 단어 n-gram 계수를 확인했다. 워드클라우드의 통계적 특이도와 모델 계수는 목적이 다르다. 워드클라우드의 코퍼스 설명용이고, 계수는 최종 분류 경계가 실제로 사용하는 방향을 보여준다. 둘이 유사한 단어를 강조할 때 해석의 신뢰가 높아진다.

어디서 틀리는가




8. 불확실성 기반 운영

Linear SVM의 결정점수는 확률이 아니다. 이 보고서는 최상위와 차상위 점수 차이를 margin으로 사용한다. 오분류 문장은 정답 문장보다 margin이 낮은 경향이 있다. 자동 분류 coverage를 낮추고 작은 margin 문장을 사람 검토로 보내면 정확도와 Macro F1이 상승한다.

권장 운영 정책:

용도	권장 처리
대시보드 집계	전체 예측 사용, 월별 성능 표본점검
고객 단위 자동 액션	낮은 margin 보류, 사람 검토 또는 중립 처리
확률값 필요	별도 검증셋에서 Platt scaling 또는 isotonic calibration 적용
신규 도메인	실제 라벨 표본 확보 후 drift·성능 재검증

불확실성 기반 운영




9. 긍정·부정 이진 분류


joy와 love를 긍정, sadness·anger·fear를 부정으로 통합하고 surprise 713건(학습 647, 테스트 66)을 제외했다. 같은 word+char TF-IDF Linear SVM을 다시 학습했다.

지표	6-class	Binary
Accuracy	0.897	0.978
Macro F1	0.856	0.978
ROC-AUC	n.a.	0.997

요구사항대로 이진 분류 성능이 6-class보다 높다. 세부 감정 간 경계보다 긍정·부정 극성 차이가 더 크기 때문이다. 다만 surprise를 제거했기 때문에 두 과제의 평가 표본이 같지 않다는 점은 함께 해석해야 한다.

Binary classification — surprise 제외





10. 재현성과 산출물

Colab 노트북은 데이터 로드, 무결성 감사, 품사 태깅, 표제어 추출, 워드클라우드, 교차검증, 최종 테스트, 오분류 분석, 이진 분류, 결과 저장을 순서대로 실행한다. 마지막 셀은 다음 파일을 생성한다.

- `mission14_multiclass_predictions.csv`
- `mission14_binary_predictions.csv`
- `mission14_multiclass_model.joblib`
- `mission14_binary_model.joblib`
- `mission14_wordcloud_keywords.csv`

11. 한계와 주의사항

1. 감정 라벨은 한 문장에 하나만 부여되어 혼합 감정을 표현하지 못한다.
2. Surprise는 긍정-부정 양쪽 의미가 섞일 수 있다.
3. SNS 텍스트의 풍자, 맥락, 화자 관계는 n-gram 모델로 완전히 파악하기 어렵다.
4. 결정 margin은 확률이 아니다. 확률 기반 의사결정에는 별도 보정이 필요하다.
5. 다른 플랫폼, 시기, 언어 변형에 적용하기 전 도메인 drift를 검증해야 한다.
6. 고객 제재·상담 우선순위 같은 고위험 의사결정에 감정 예측을 단독으로 사용해서는 안 된다.

12. 결론

시각화와 분류는 서로 다른 전처리가 최적이었다. 워드클라우드에는 품사 제한·표제어·공통어 제거·감정 특이도 가중이 효과적이었고, 분류에는 최소 정제와 word+character TF-IDF 결합이 효과적이었다. 최종 6-class 모델은 정확도 89.7%, Macro F1 0.856, 이진 모델은 정확도 97.8%를 기록했다. 운영에서는 낮은 margin 예측을 보류하고, 신규 도메인에서 성능과 drift를 지속 점검해야 한다.